

Segmentation par régions

Michel Roux

Institut Mines Télécom, Télécom ParisTech

26 septembre 2022



Objectifs de la segmentation par régions :
déterminer les régions homogènes d'une image

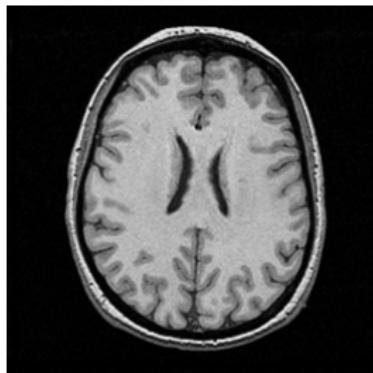


image de cerveau (IRM)

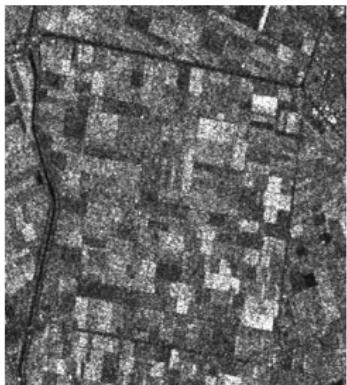


image radar



image couleur

Segmentation par régions

Difficultés :

- des objets plus ou moins complexes (matière blanche),
- du bruit présent dans les images (speckle)
- divers types de données (niveaux de gris, couleur, ..., images hyper-spectrales,

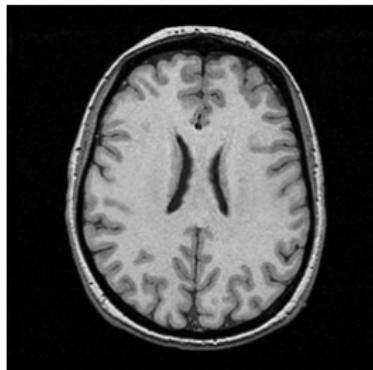


image de cerveau (IRM)



image radar

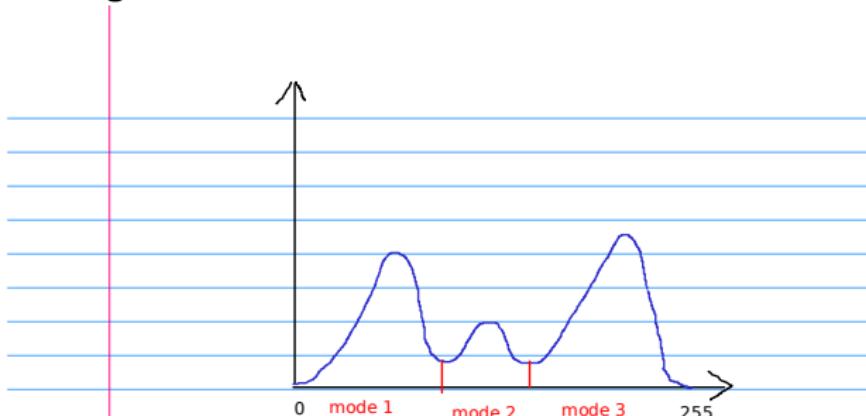


image couleur

- Décomposition d'une image en formes élémentaires
 - approche duale de la détection de contours
 - recherche de zones possédant des attributs communs
- Méthodes
 - approches sur **histogramme - classification**
 - approches par **transformation de régions**
 - approches théoriques par **minimisation d'une fonctionnelle**

- **Principe**
 - utiliser les modes de l'histogramme
 - classification → segmentation
- **Avantages et limites**
 - (+) simple
 - (+) adapté à plusieurs dimensions
 - (-) pour images sans bruit (pas de critère de cohérence spatiale)
- **Deux types d'approches**
 - approches **supervisées**
 - apprendre chaque classe à partir de données connues
 - approches **automatiques**
 - pas de données d'apprentissage
 - connaissance a priori du nombre de classes, ou non

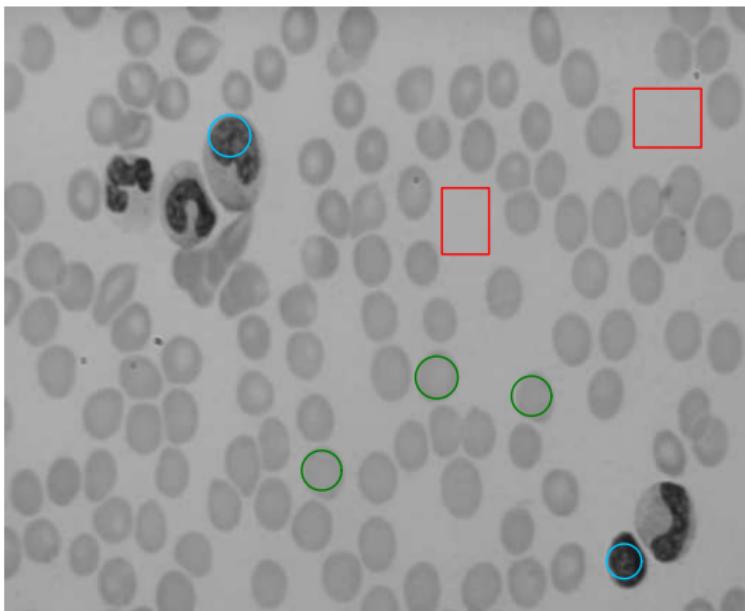
modes d'un histogramme



mode : ensemble des niveaux de gris compris
entre deux minima de l'histogramme

Segmentation par régions

Données d'apprentissage sélectionnées manuellement



- Modélisation probabiliste de l'image

- $\Omega = \{\omega_1, \omega_2, \dots\}$ l'ensemble des classes
- s un site (pixel) et $S = \{s\}$ l'ensemble des sites
- Y_s variable aléatoire associée à chaque site
- y_s le niveau de gris (réalisation de Y_s)

- Principe

au site s on affecte la classe ω_i telle que :

$$P(\omega_i|y_s) \text{ maximale}$$

- Règle de Bayes

$$P(\omega_i|y_s) = \frac{P(y_s|\omega_i)P(\omega_i)}{P(y_s)}$$

Méthode supervisée

- Probabilité $P(y_s|\omega_i)$

apprentissage sur un ensemble de données classées
histogrammes \Rightarrow distribution des niveau de gris
(méthodes paramétriques -modèles gaussiens- ou non)

- Probabilité a priori $P(\omega_i)$

connaissance a priori de la fréquence d'apparition des classes
sinon équiprobabilité des classes

$$P(\omega_i) = \frac{1}{\text{card } (\Omega)} \Rightarrow P(y_s|\omega_i) \text{ maximale}$$

(classification au sens du maximum de vraisemblance -MV-)

- Cas de deux classes

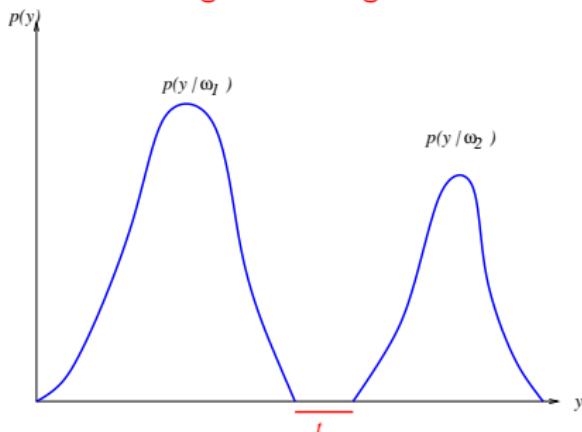
$$\Omega = \{\omega_1, \omega_2\}$$

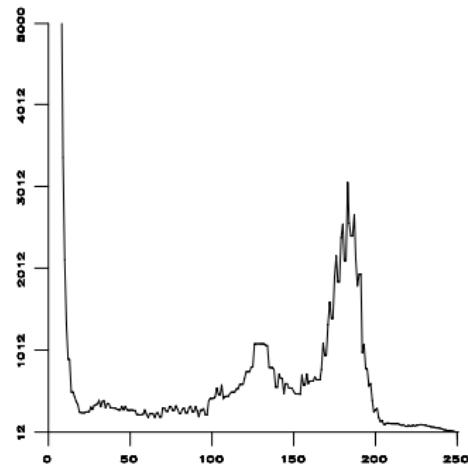
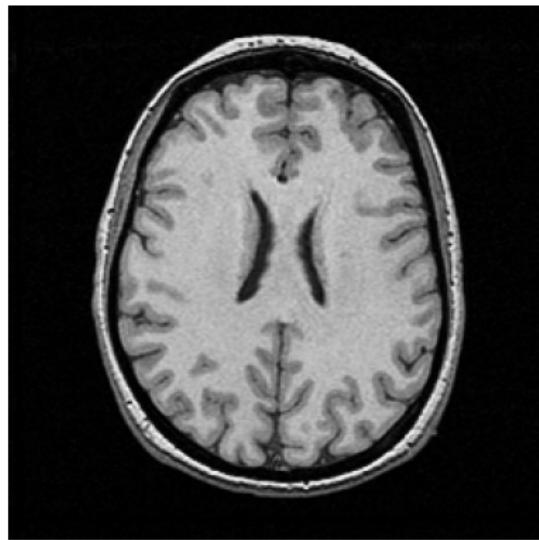
soit un site s et y_s son niveau de gris

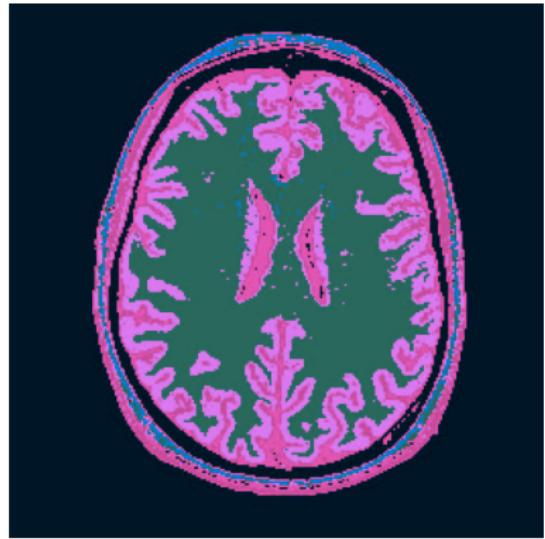
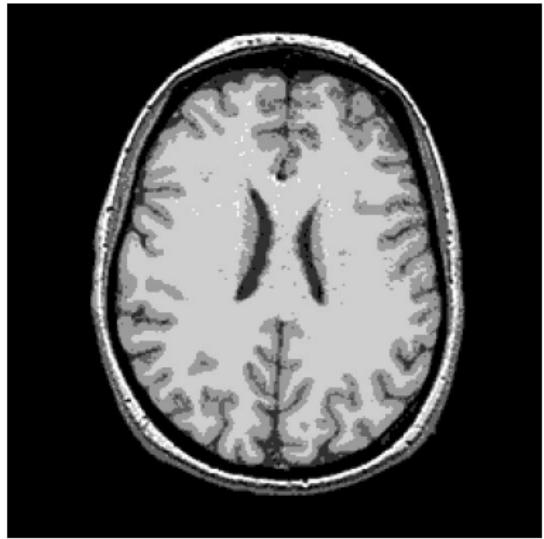
si $P(\omega_1|y_s) > P(\omega_2|y_s) \Rightarrow s$ est dans ω_1

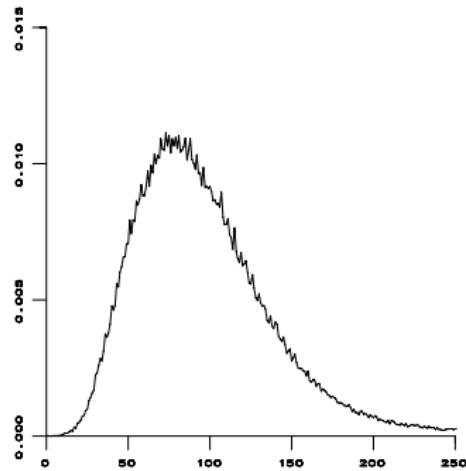
\Leftrightarrow si $y_s < t \Rightarrow s$ est dans ω_1

en 1D : **seuillage de l'histogramme**

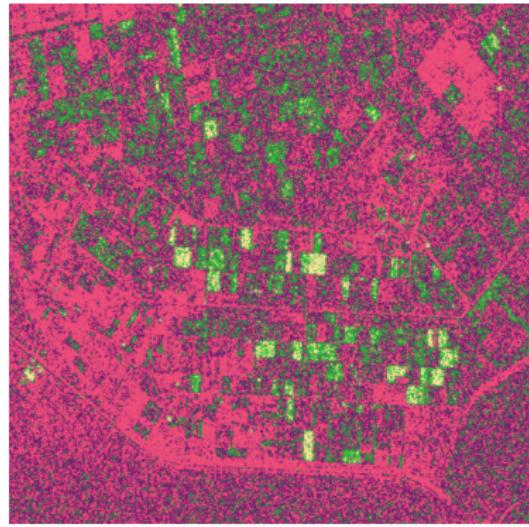
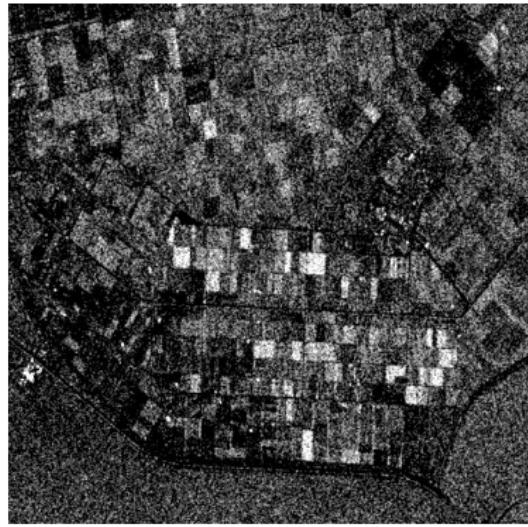








Imagerie radar



- Introduction d'une fonction de coût

$$\Omega = \{\omega_1, \omega_2\}$$

Pondération des classes : coûts de mauvaise classification :

C_i coût de mauvaise classification de la classe i

- $\Gamma(t)$ coût global de mauvaise classification pour un seuil t :

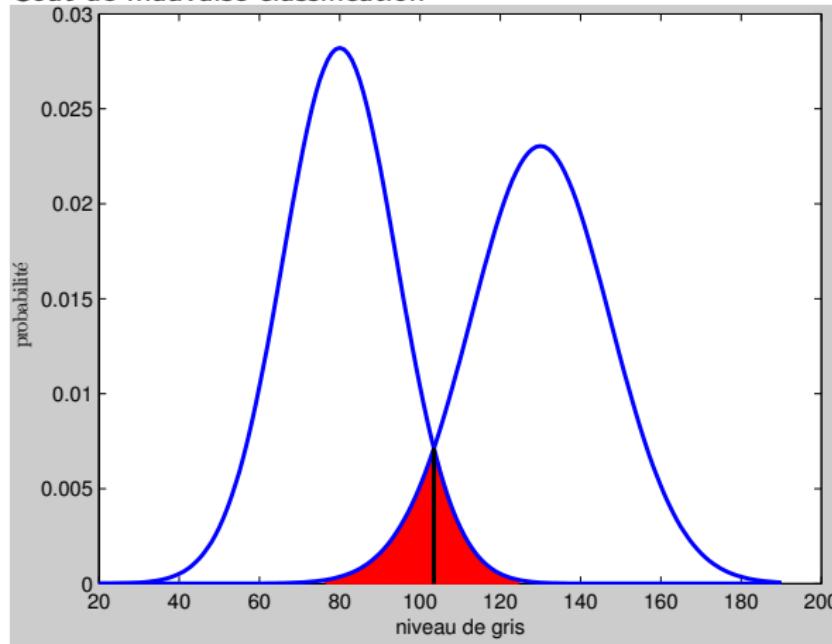
$$\Gamma(t) = C_1 \int_t^N P(\omega_1)P(y|\omega_1)dy + C_2 \int_0^t P(\omega_2)P(y|\omega_2)dy$$

- Choix du seuil t qui minimise la fonction de coût $\frac{\partial \Gamma(t)}{\partial t} = 0$:

$$C_1 P(\omega_1)P(t|\omega_1) - C_2 P(\omega_2)P(t|\omega_2) = 0$$

(test du rapport de vraisemblance $\Lambda(t) = \frac{P(t|\omega_1)}{P(t|\omega_2)}$ par rapport à $\frac{C_2 P(\omega_2)}{C_1 P(\omega_1)}$ pour chaque seuil t)

Coût de mauvaise classification



• Seuillage de Neyman-Pearson

- probabilité de fausse alarme pour un seuil t donné :

$$P_{fa} = \int_0^t P(\omega_2)P(y|\omega_2)dy$$

(probabilité de classer un point de la classe ω_2 dans la classe ω_1)

- probabilité de détection :

$$P_d = \int_0^t P(\omega_1)P(y|\omega_1)dy$$

- calcul de la courbe COR -*Receiver Operating Charcateristic-* (P_d en fonction de P_{fa})
- choix du point de fonctionnement (maximisation de la P_d à P_{fa} fixée)

pas d'ensemble d'apprentissage

==>

méthodes non supervisées

- détection des modes de l'histogramme, méthode du fingerprint,
- approches itératives, méthode des k-moyennes,
- parcours exhaustif des solutions, seuillage de Otsu.

- Seuillages sans apprentissage

- **Principe** : recherche des maxima et minima locaux pour définir les classes sur l'histogramme (isoler les modes entre deux vallées)
- **Méthode** : soit $f(x)$ l'histogramme, recherche des passages par zéro de $f'(x)$ et de $f''(x)$ (détermination de moyennes et variances pour des distributions gaussiennes)

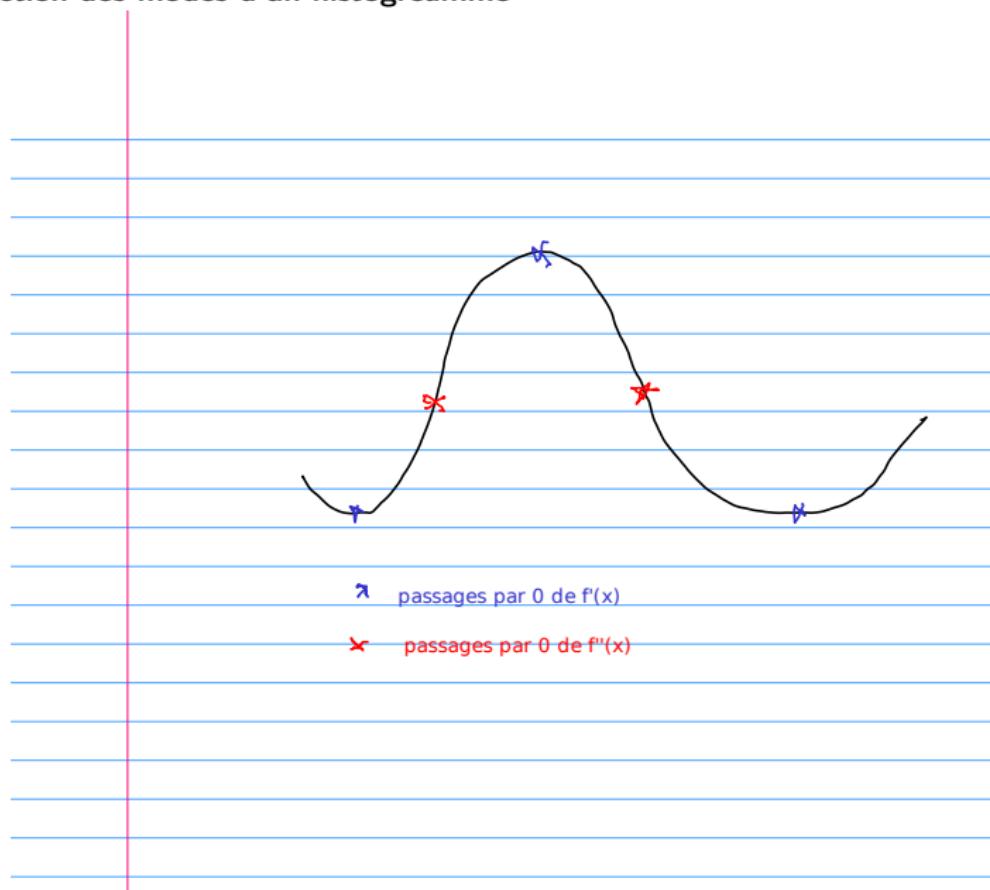
- **Traitements du bruit** :

filtrage de l'histogramme avec des gaussiennes

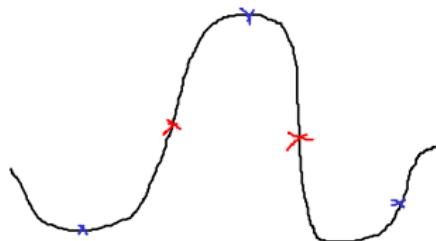
- **Méthode du "fingerprint"**

- filtrage avec des noyaux gaussiens de σ croissants
- courbe des passages par zéro de $f''(x, \sigma)$ en fonction de σ
- seuillage à un σ_0 fixé (compromis entre le bruit présent et la faible représentation d'une classe)

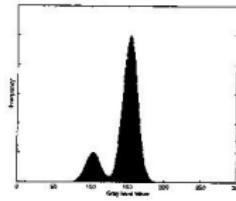
Détection des modes d'un histogramme



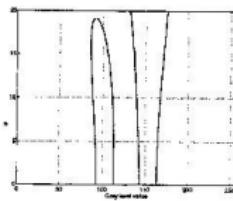
Test



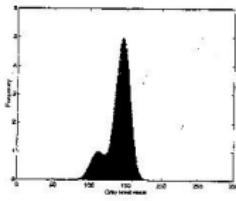
Fingerprints



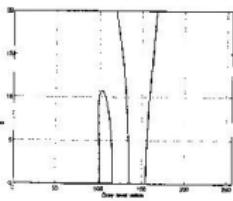
a)



b)

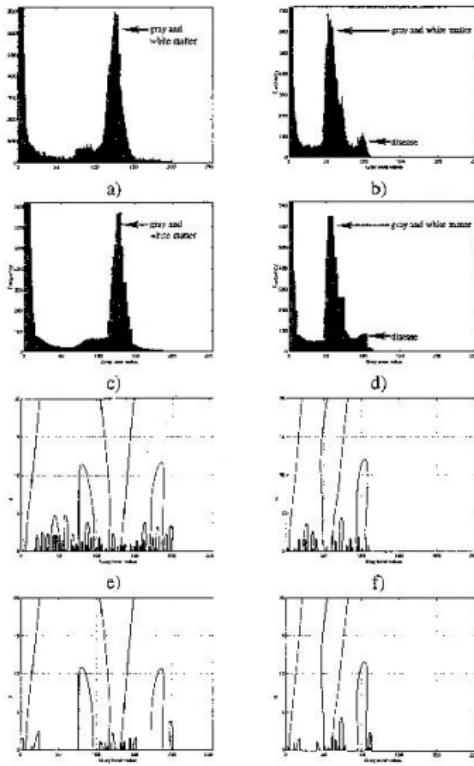


c)

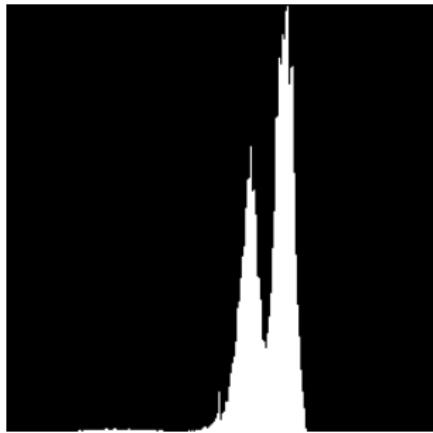
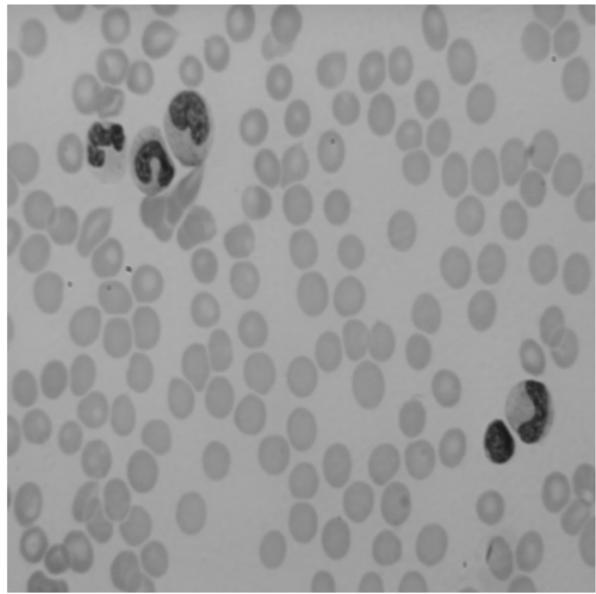


d)

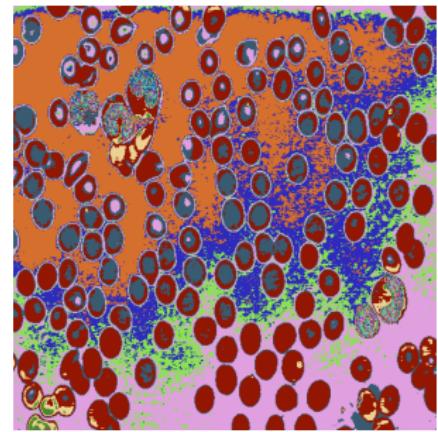
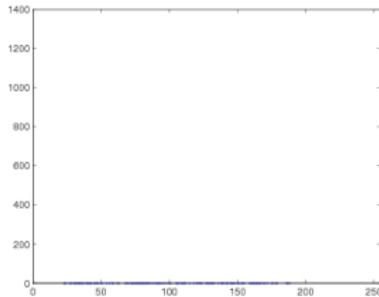
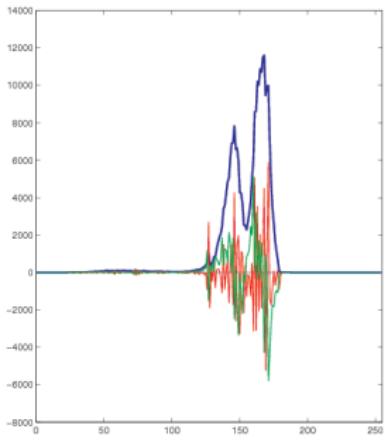
Fingerprints



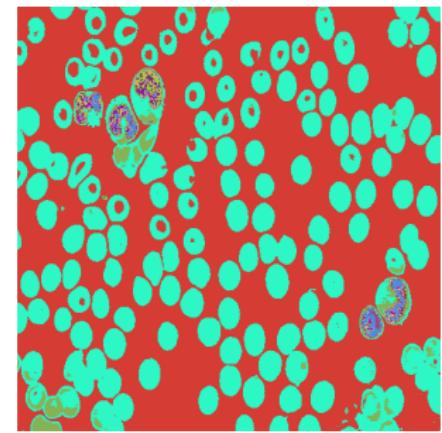
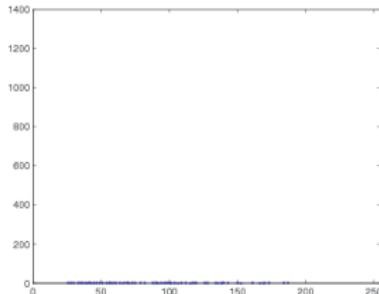
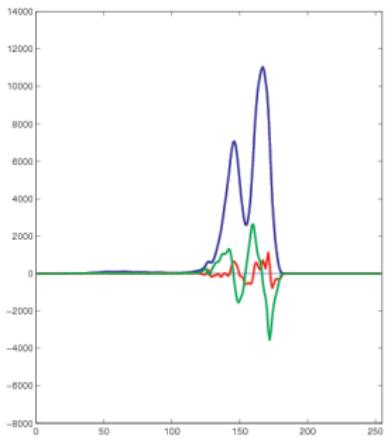
Fingerprints : exemple



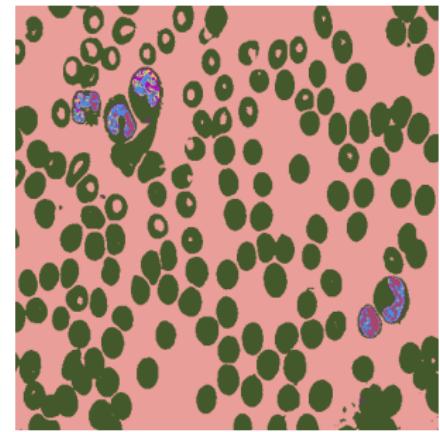
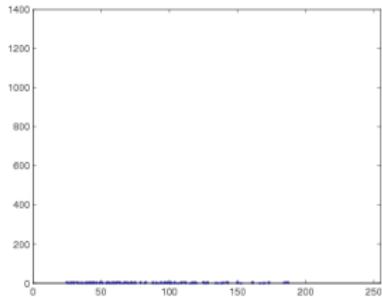
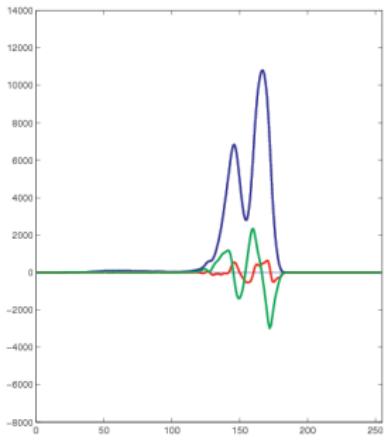
Fingerprints



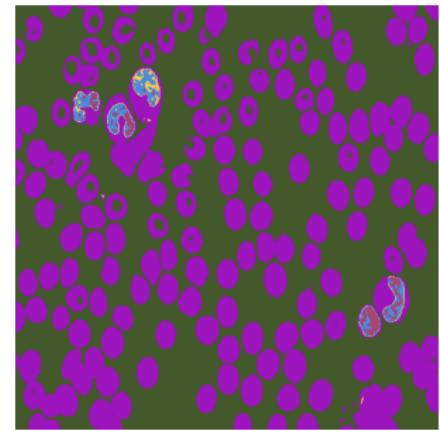
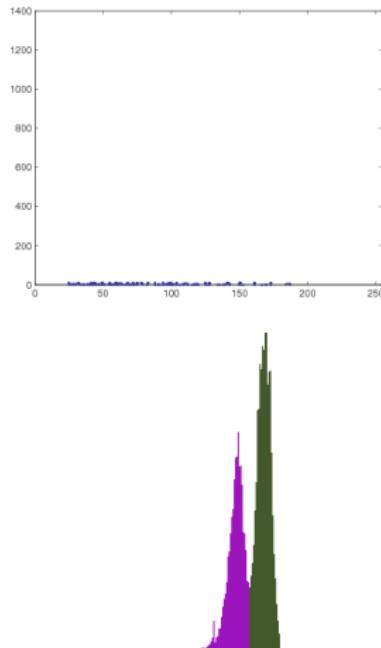
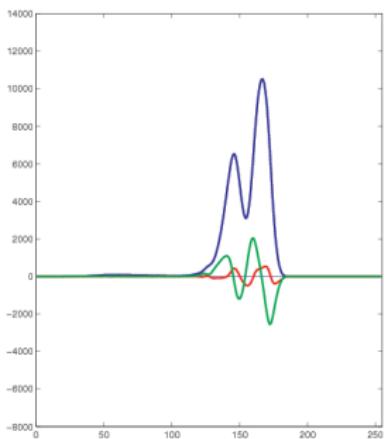
Fingerprints



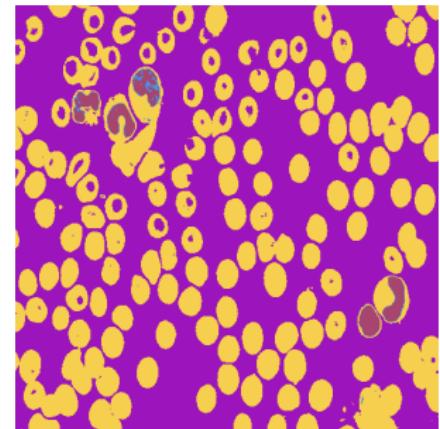
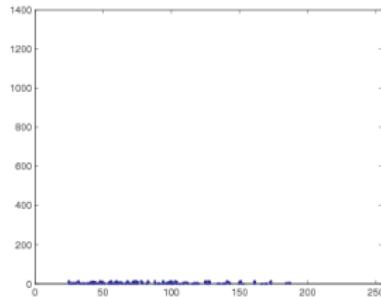
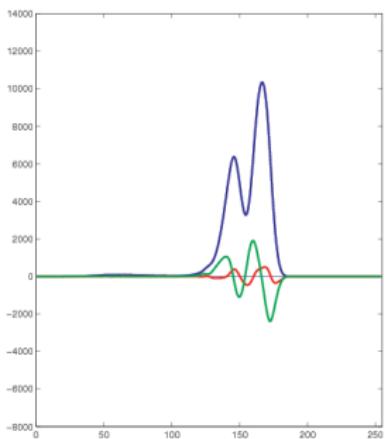
Fingerprints



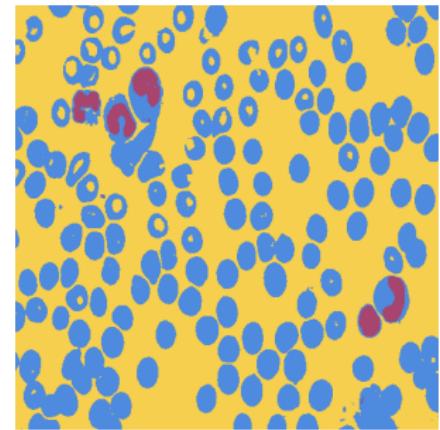
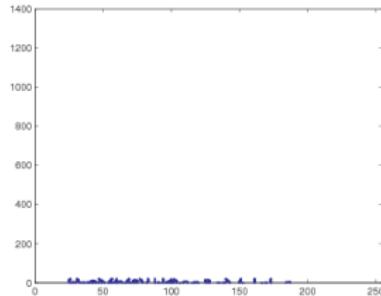
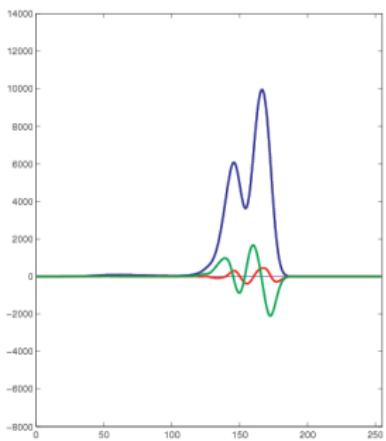
Fingerprints



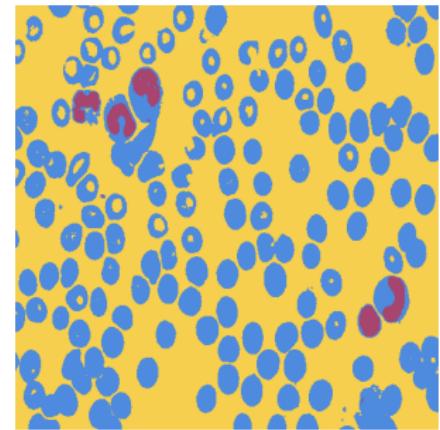
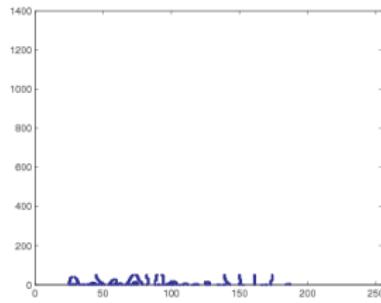
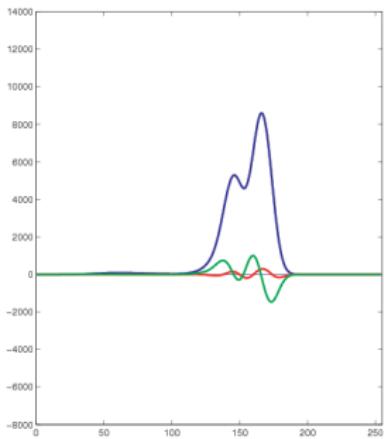
Fingerprints



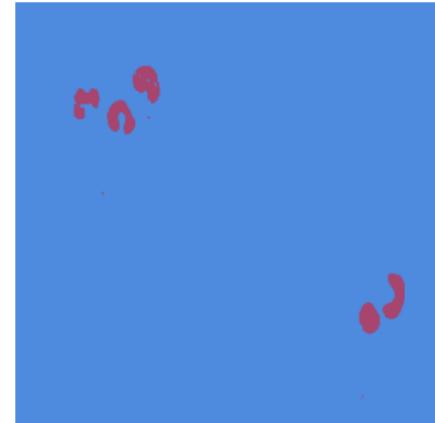
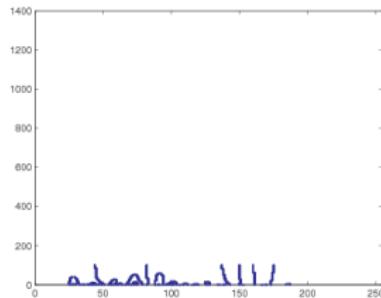
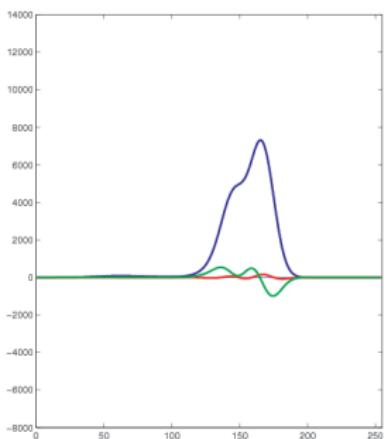
Fingerprints



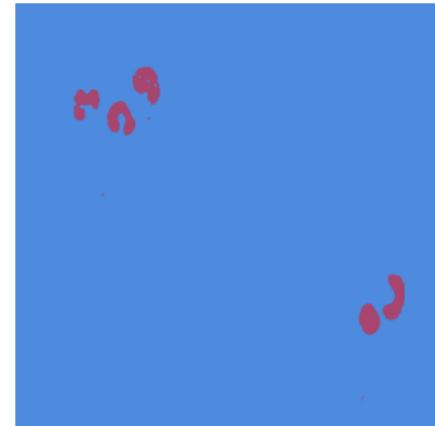
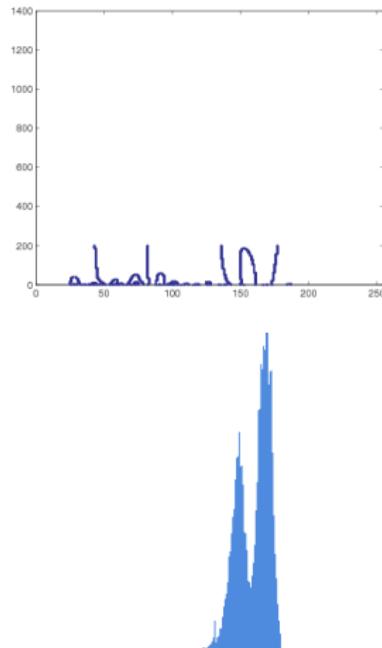
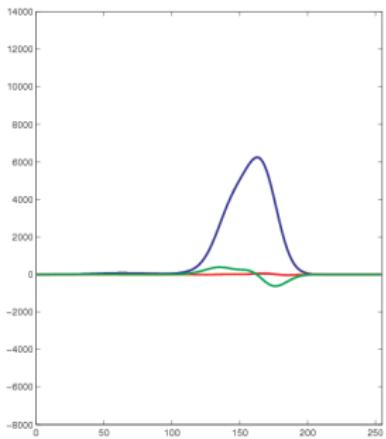
Fingerprints



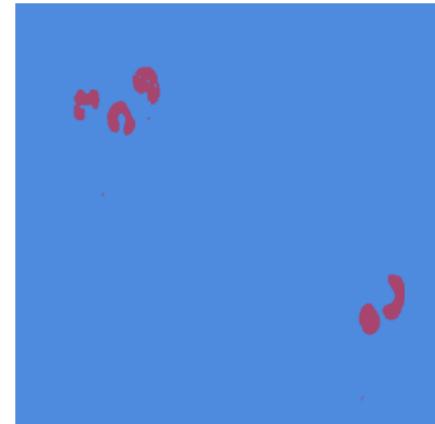
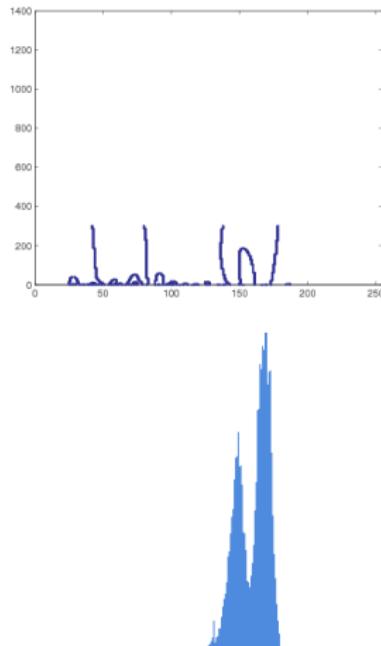
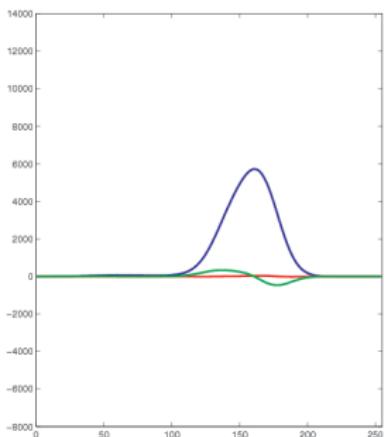
Fingerprints



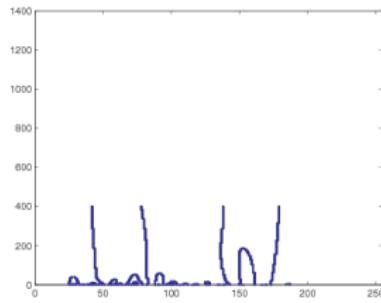
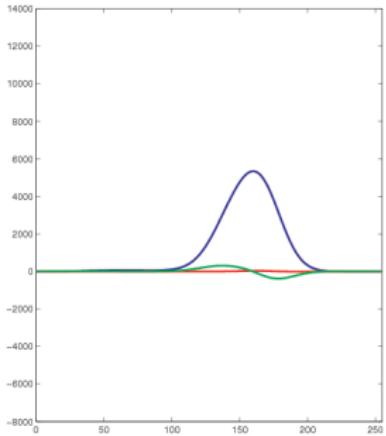
Fingerprints



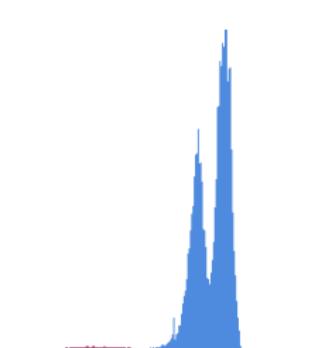
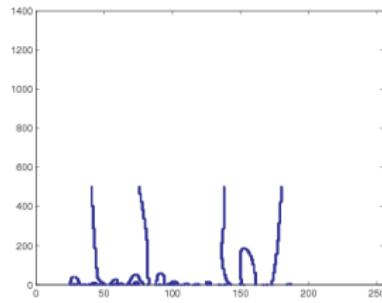
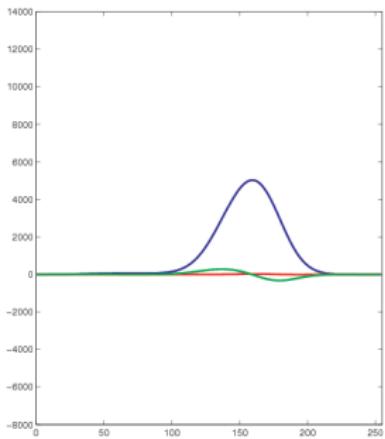
Fingerprints



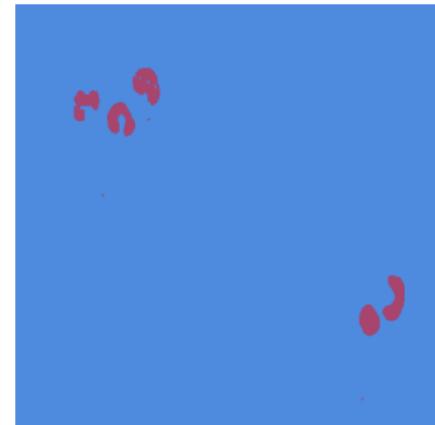
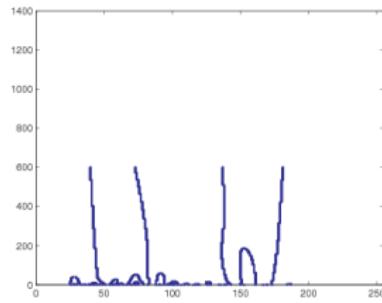
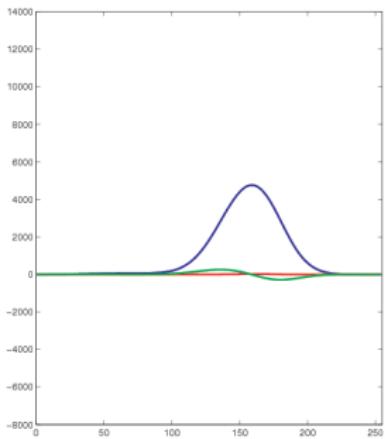
Fingerprints



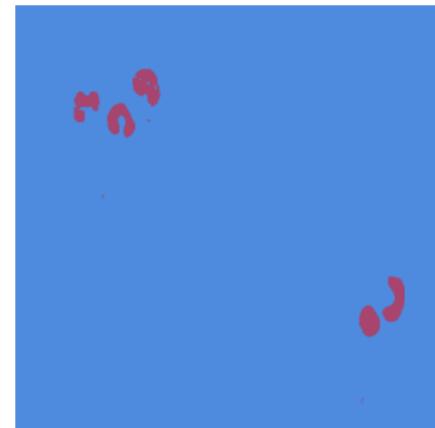
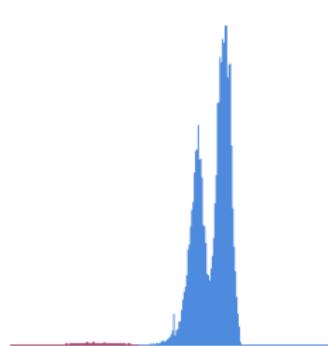
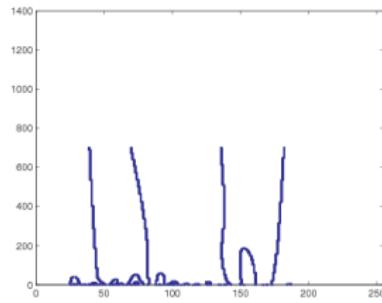
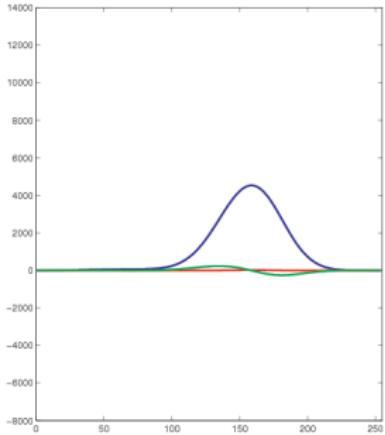
Fingerprints



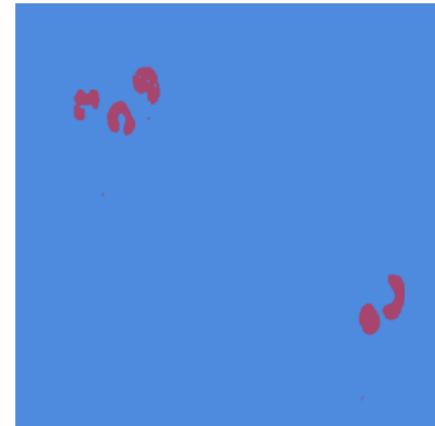
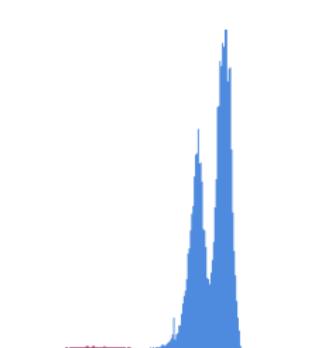
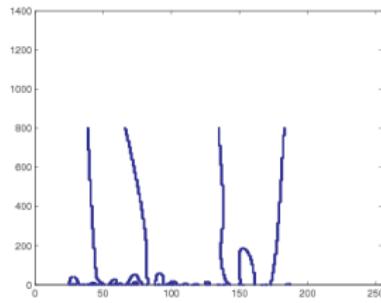
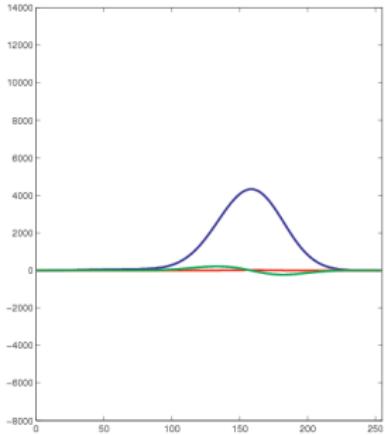
Fingerprints



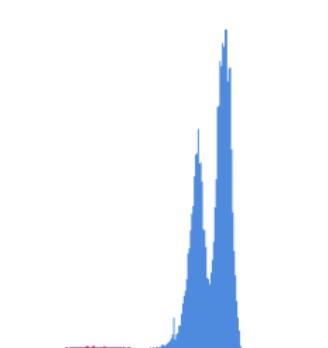
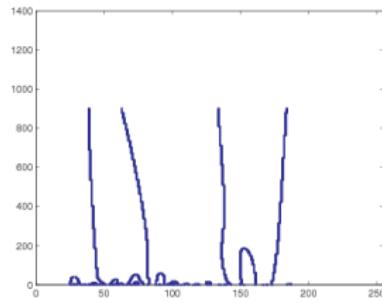
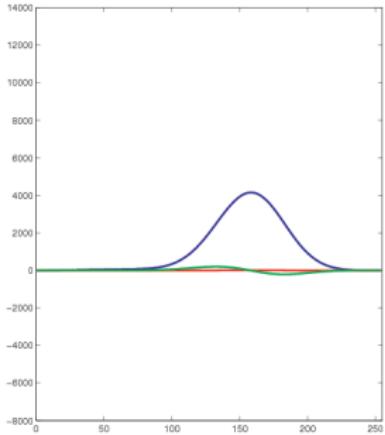
Fingerprints



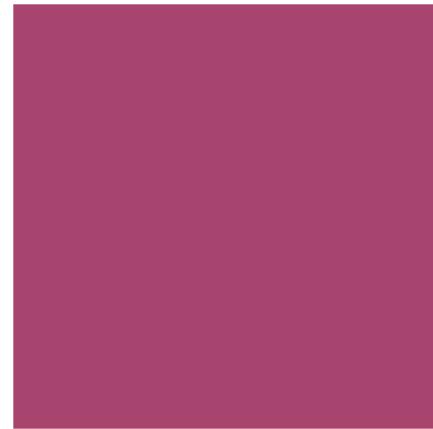
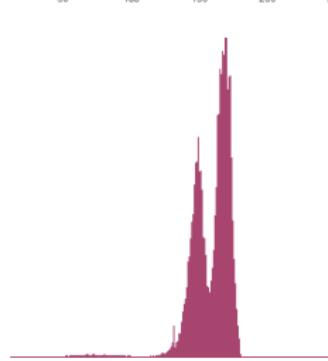
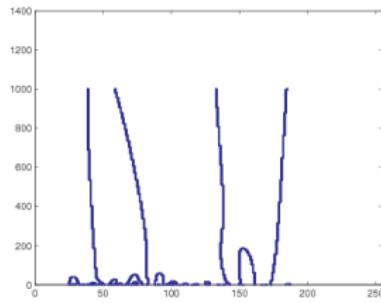
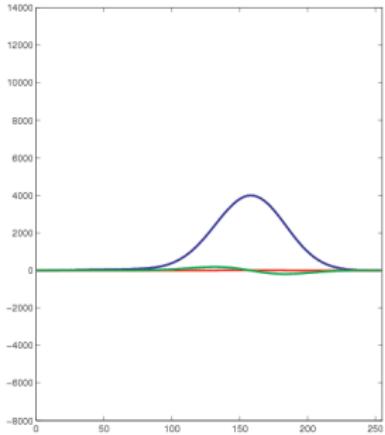
Fingerprints



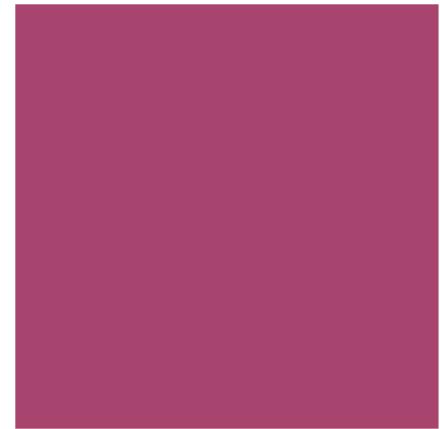
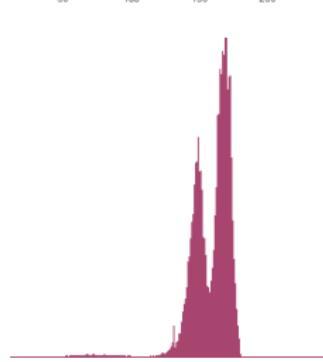
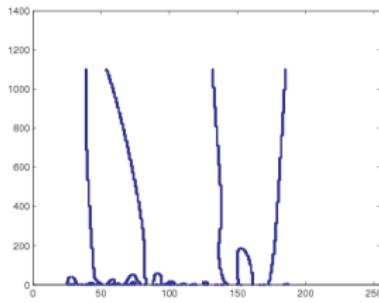
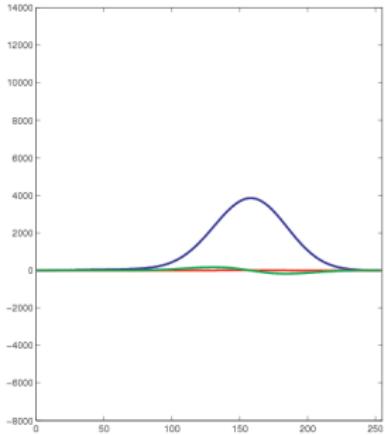
Fingerprints



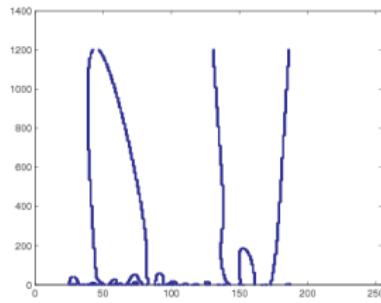
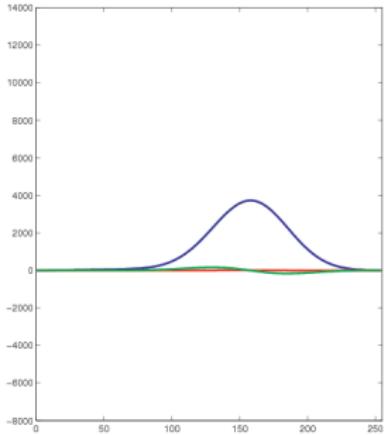
Fingerprints



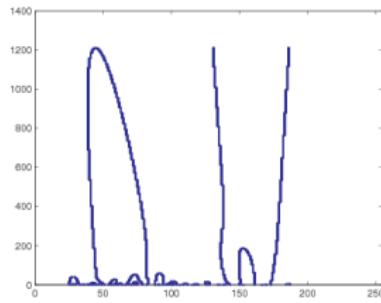
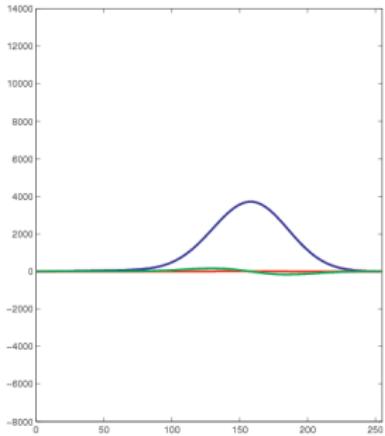
Fingerprints



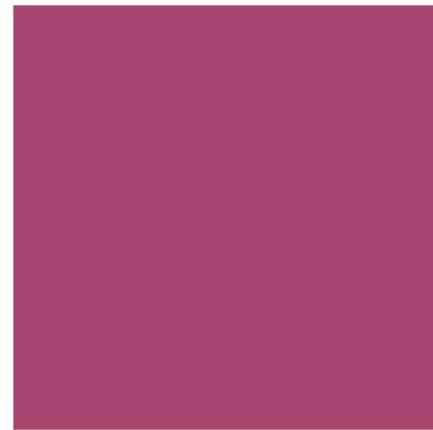
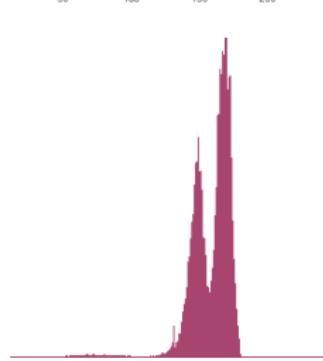
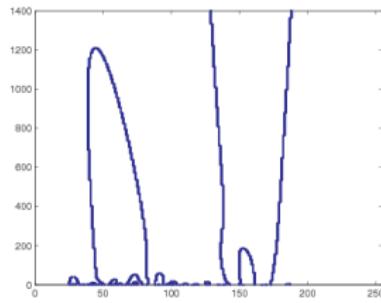
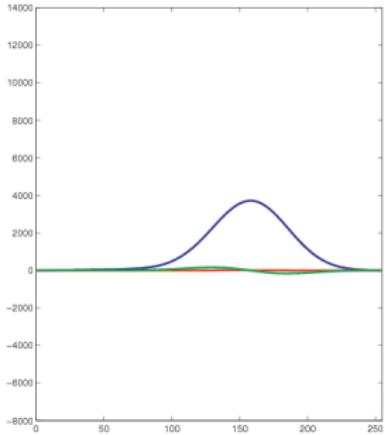
Fingerprints



Fingerprints



Fingerprints



pas d'ensemble d'apprentissage, méthodes non supervisées (en 1-D ou n-D)

- **Algorithme des k-moyennes**

connaissance a priori du nombre de classes (k)

recherche de la "meilleure" répartition des pixels (ng) en k classes

- **Principe** : minimisation de la dispersion intra-classe (\Leftrightarrow maximisation de la dispersion inter-classes)

- **Méthode** :

- initialisation des centres de classes
 - classification des points par rapport à leur distance aux centres
 - calcul de nouveaux centres (centres de gravité)
 - itération jusqu'à stabilisation des centres

- **Inconvénient** : pas de preuve de convergence vers l'optimum global (dépend de l'initialisation)

- **mono-canal** : en 1D, tout peut se faire sur l'histogramme

Ex pour 2 classes :

valeurs initiales des centres $m_1^0 = 10$; $m_2^0 = 120$

affectation initiale : seuillage à $t = 65$ (histogramme)

calcul des nouveaux centres :

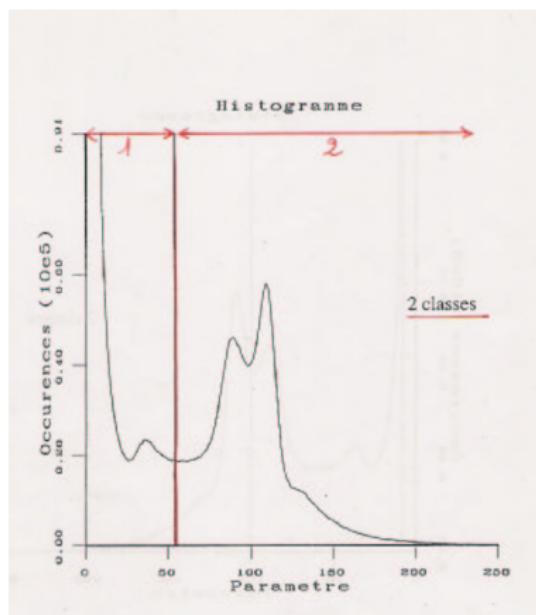
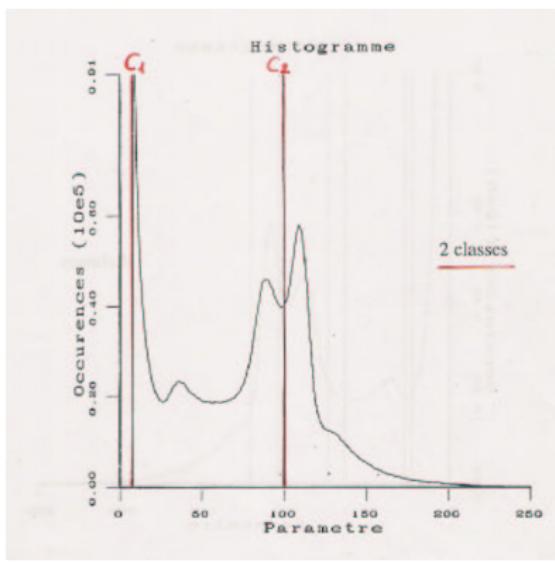
$$m_1^1 = \frac{1}{\sum_{n=0}^{n=t} f_n} \sum_{n=0}^{n=t} n f_n$$

$$m_2^1 = \frac{1}{\sum_{n=t}^{n=N} f_n} \sum_{n=t}^{n=N} n f_n$$

- **multi-canaux** : à plusieurs dimensions, importance du coût de stockage de l'histogramme \Rightarrow passages successifs sur l'image
- Application aux espaces de grande dimension : réduction de la taille de l'espace par ACP

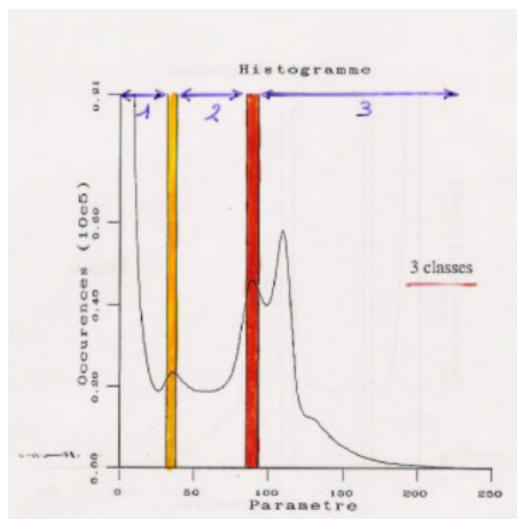
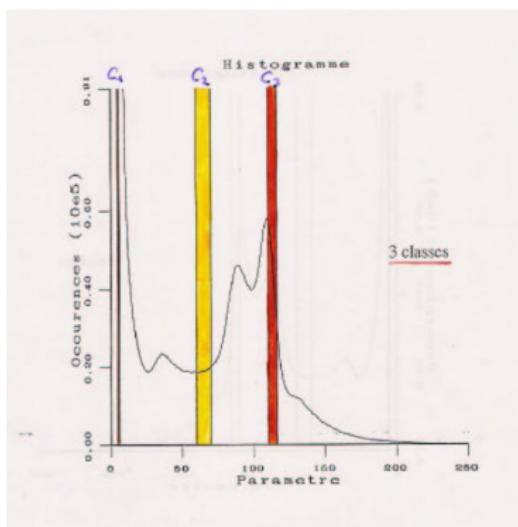
Méthodes de classification automatique : k-moyennes

- Variabilité (2 classes)



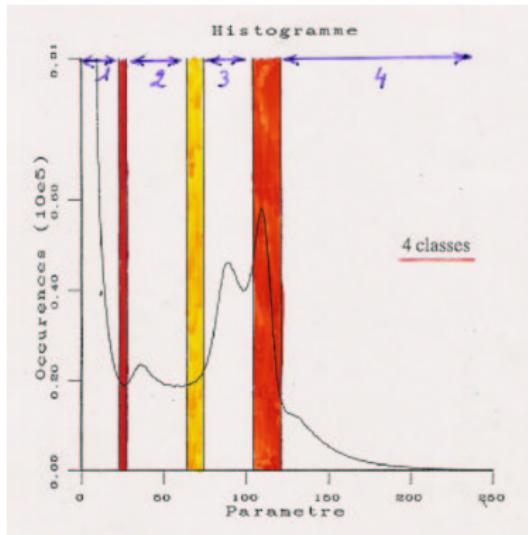
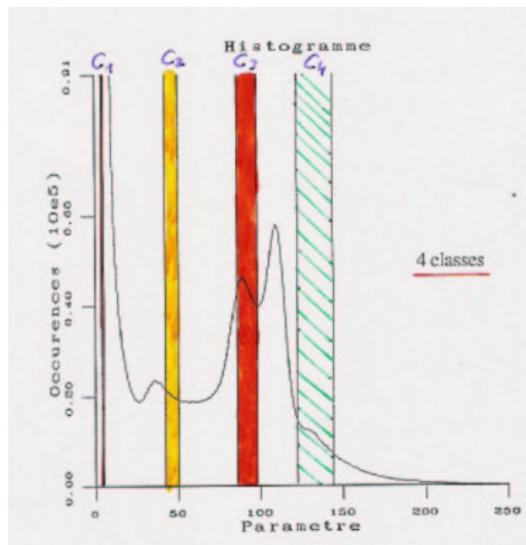
Méthodes de classification automatique : k-moyennes

- Variabilité (3 classes)



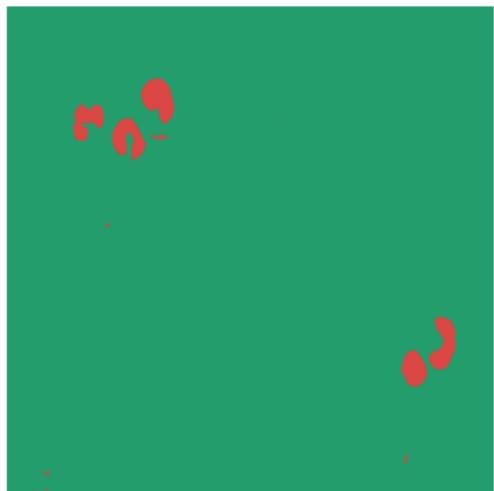
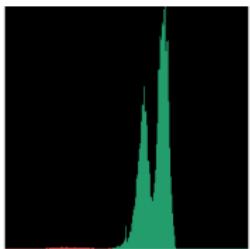
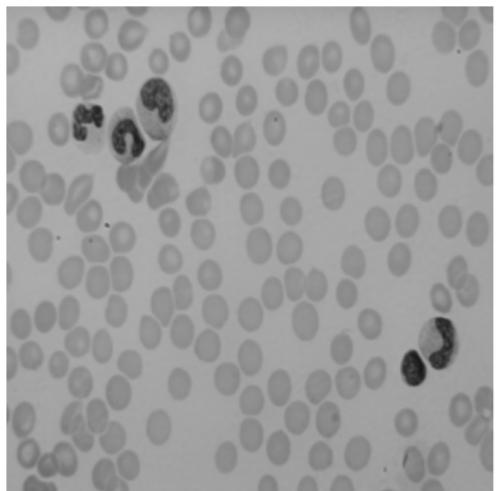
Méthodes de classification automatique : k-moyennes

- Variabilité (4 classes)



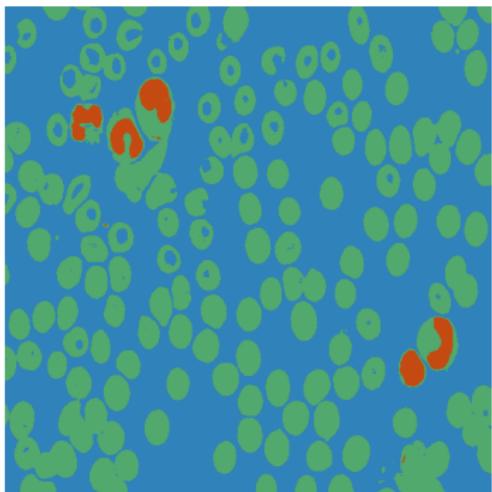
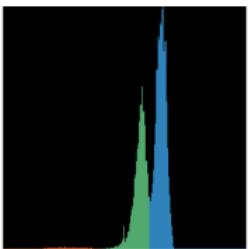
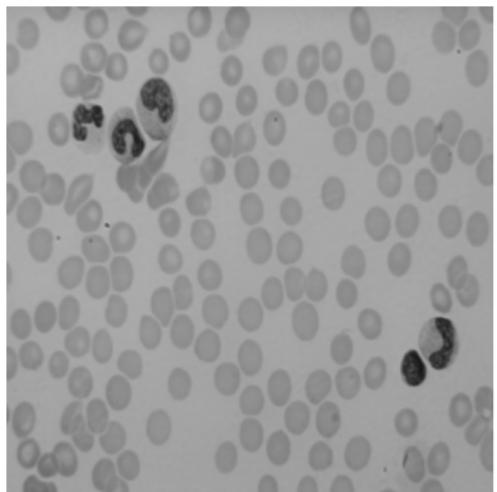
Méthodes de classification automatique : k-moyennes

2 classes



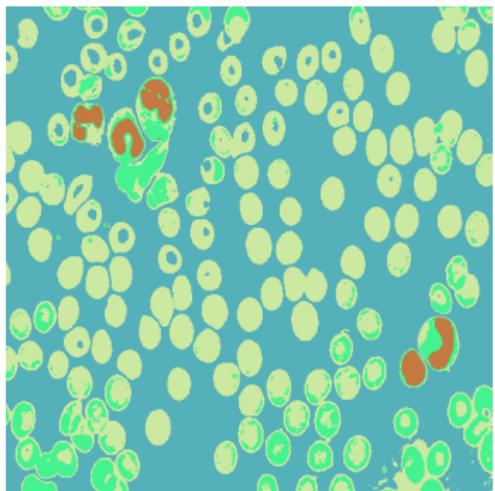
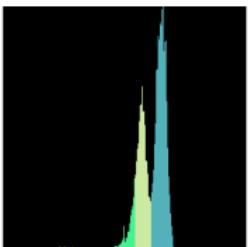
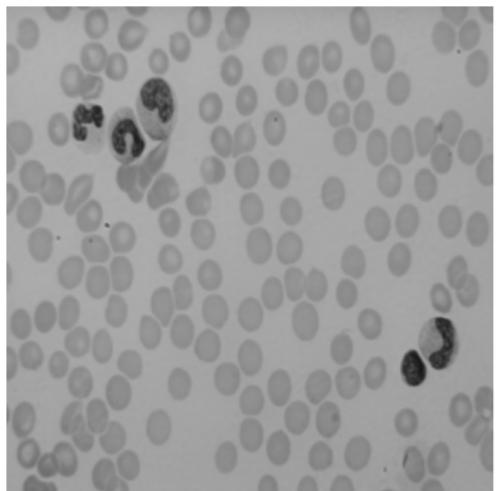
Méthodes de classification automatique : k-moyennes

3 classes



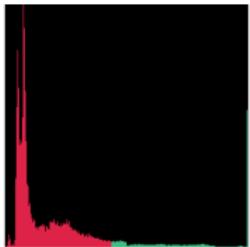
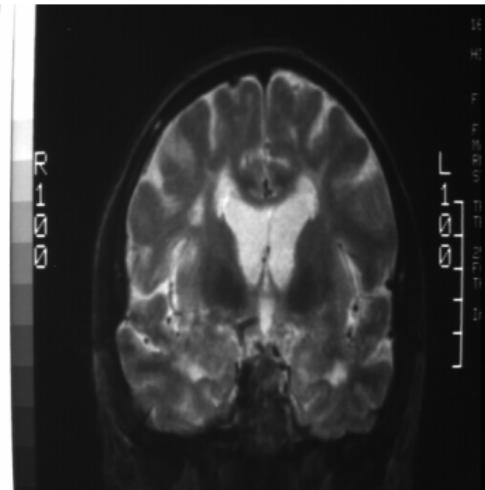
Méthodes de classification automatique : k-moyennes

4 classes



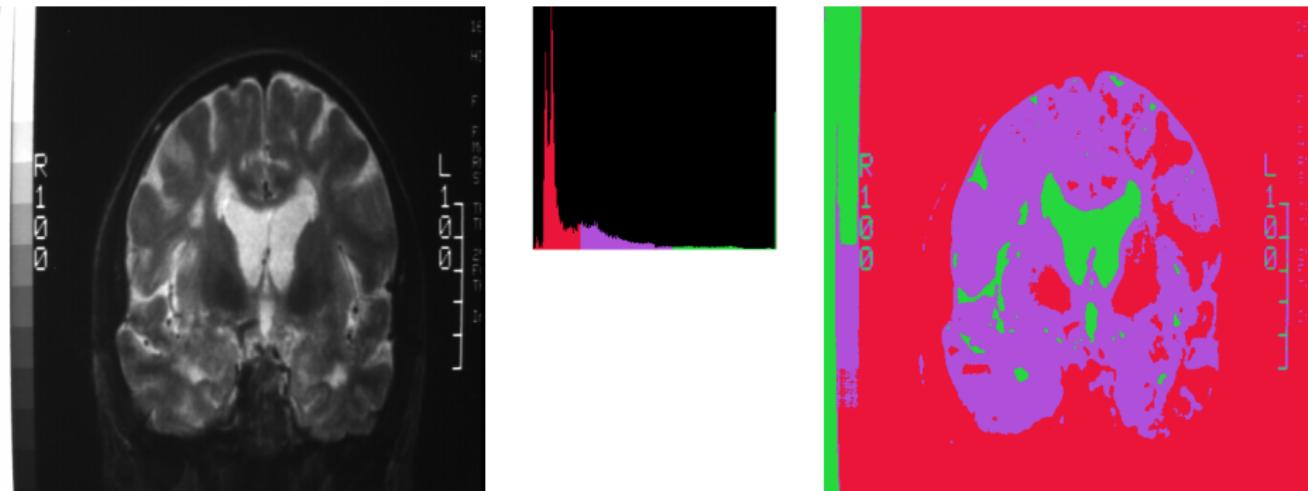
Méthodes de classification automatique : k-moyennes

2 classes



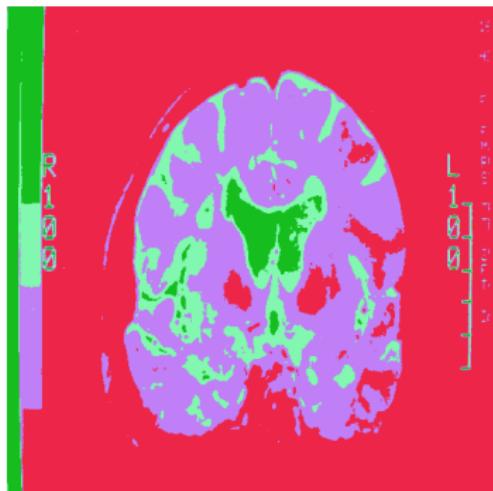
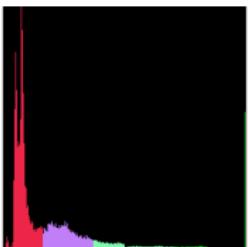
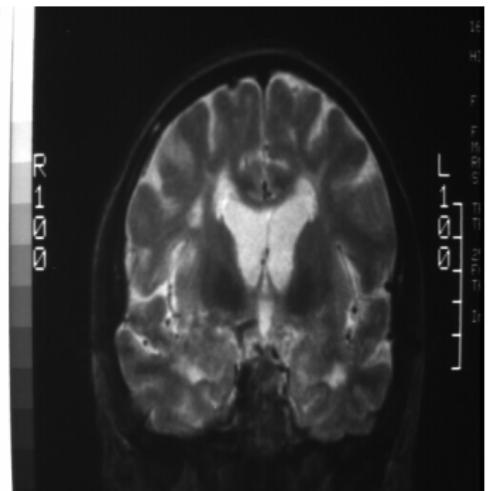
Méthodes de classification automatique : k-moyennes

3 classes



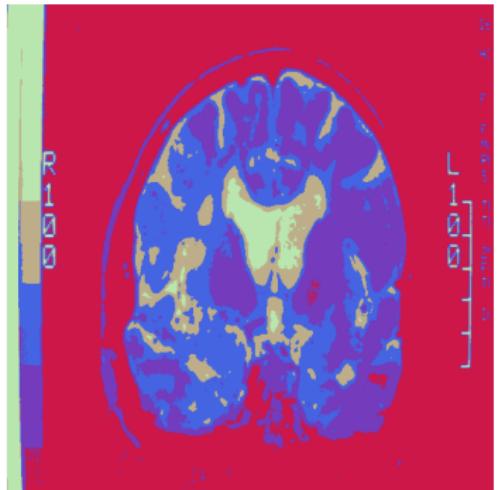
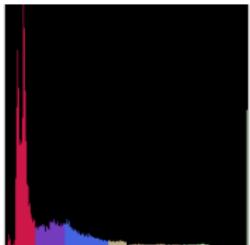
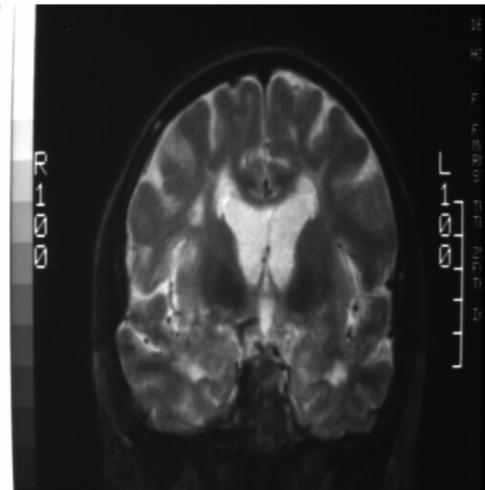
Méthodes de classification automatique : k-moyennes

4 classes



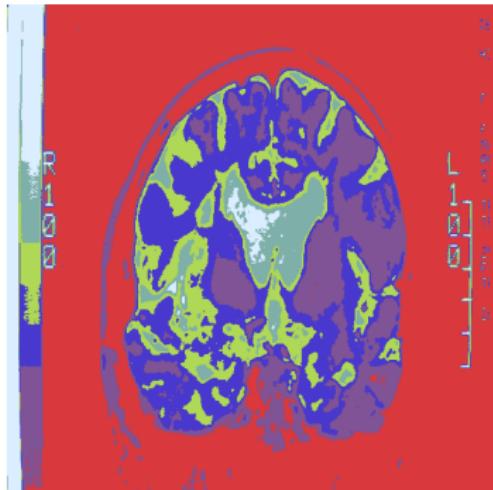
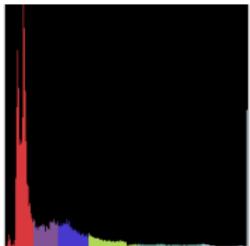
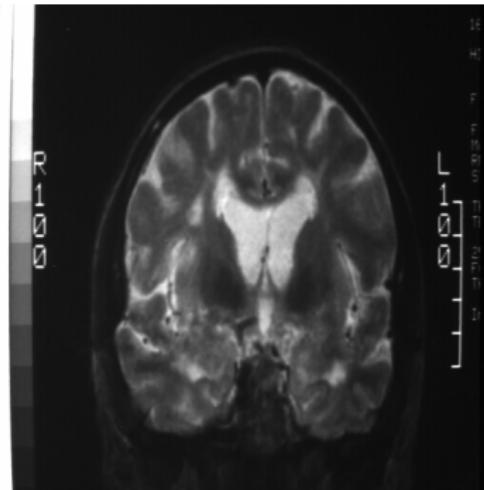
Méthodes de classification automatique : k-moyennes

5 classes



Méthodes de classification automatique : k-moyennes

6 classes



Méthodes de classification automatique : k-moyennes

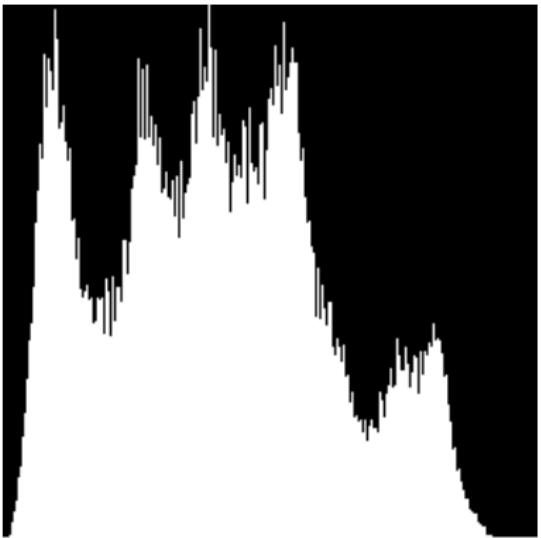


image originale / 16 classes / 32 classes



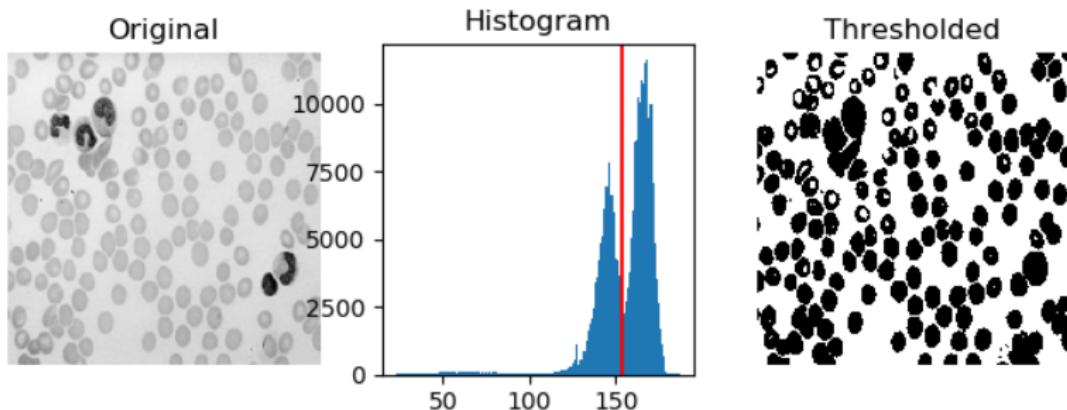
Méthodes de classification automatique : k-moyennes

image originale / 10 classes / 50 classes

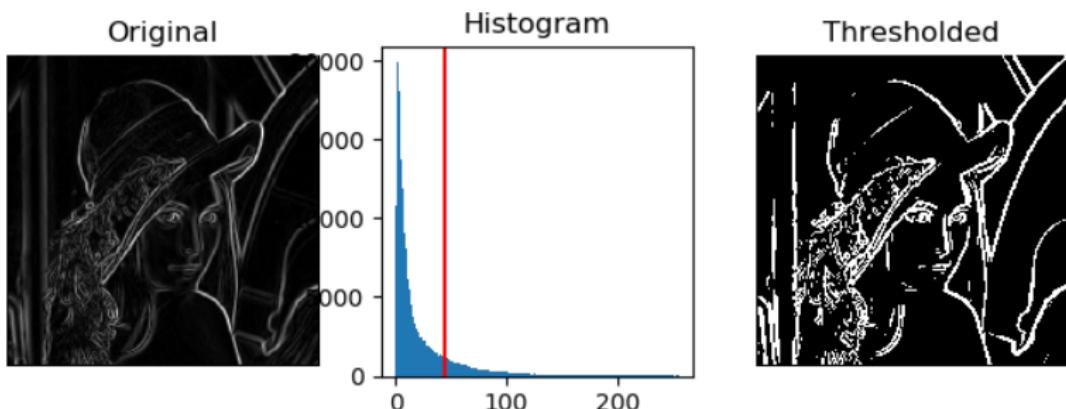


Méthodes de seuillage automatique : méthode de Otsu

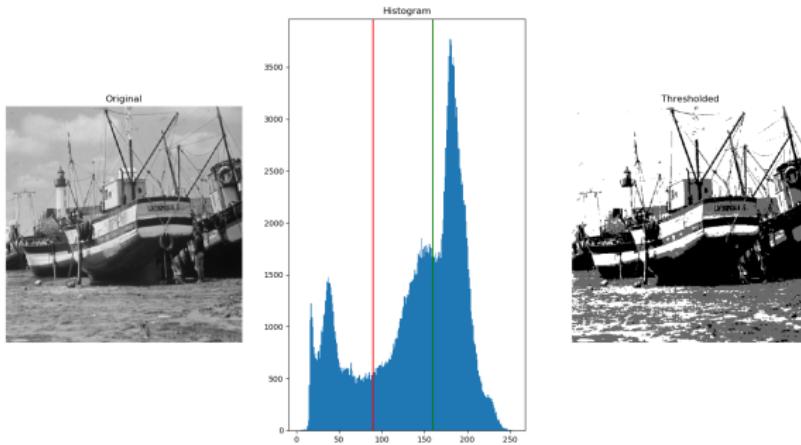
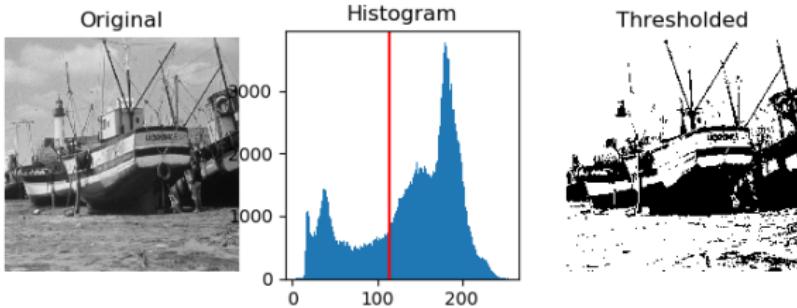
- choix d'un critère à optimiser,
minimiser la dispersion intra-classe, par exemple,
- parcours exhaustif de toutes les possibilités,
ici, tous les seuils entre 0 et 256
- choix de la meilleure solution.



Méthodes de seuillage automatique : méthode de Otsu



possibilité d'étendre à plusieurs seuils



classifications "**ponctuelles**" : chaque pixel classé indépendamment des autres
⇒ résultats bruités

- Filtrage des images
- Approches Markoviennes
- Analyse des composantes connexes

Sélection itérative des plus grandes régions après chaque seuillage de l'histogramme

(méthode d'Ohlander et Price)

- modélise le problème : $y \rightarrow x ?$

$$\Pr(X = x / Y = y) = \frac{\Pr(Y = y / X = x) \cdot \Pr(X = x)}{\Pr(Y = y)} \quad [\text{Bayes}]$$

$\Pr(X = x / Y = y) \propto$	$\Pr(Y = y / X = x) \cdot$	$\Pr(X = x)$
↓	↓	↓
probabilité a posteriori de x	formation des observations	a priori sur la solution

- estimateur MAP : $\hat{x} = \arg \max_{x \in \Omega} \Pr(X = x / Y = y)$

- Minimisation d'une énergie

Minimisation d'une énergie définie globalement sur l'image :

$$U(x) = U(x, y) + U_{prior}(x)$$

de la forme

$$U(x) = \sum_s f(x_s, y_s) + \sum_{s,t} g(x_s, x_t)$$

$U(x, y)$ attache aux données (les classes doivent respecter les niveaux de gris)
 $U_{prior}(x)$ terme contextuel (les classes des pixels voisins doivent être en accord)



(a)

(b)



(c)

(d)

- Minimisation d'une énergie
- Exemple : champ gaussien et modèle de Potts

$$U(x) = \sum_s (\mu_{x_s} - y_s)^2 - \beta \sum_{s,t} \delta(x_s, x_t)$$

- favorise les régions compactes
- β compromis entre la fidélité aux observations et la régularité imposée

Recherche de la configuration la plus probable i.e d'énergie minimale
Pas de solution analytique

- **Recuit simulé**

méthode stochastique, itérative avec paramètre de température décroissante
inconvénient : lenteur de la convergence

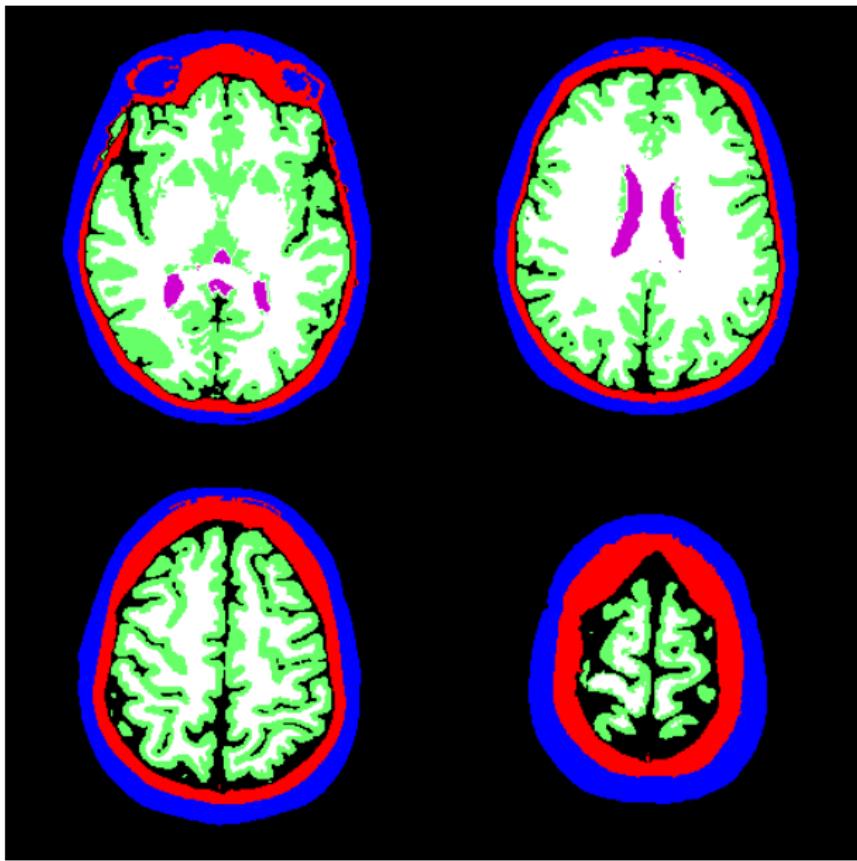
- **ICM (modes conditionnels itérés)**

algorithme déterministe, convergence vers un minimum local
principe : en chaque site, on choisit la classe qui fait le plus diminuer l'énergie locale

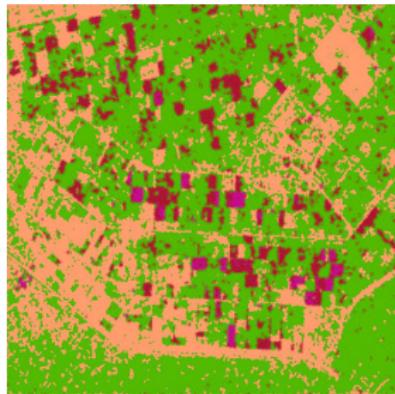
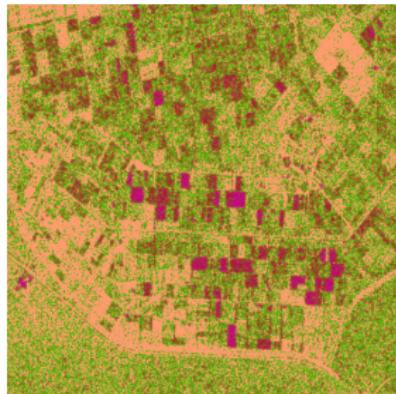
- **Graph-cut**

principe : partitionnement d'un graphe en sous-graphes par coupe de capacité minimale

Régularisation markovienne : exemple



Régularisation markovienne : exemple



Intérêt : prise en compte directe de la cohérence spatiale

- Notion de partition Π

ensemble de sous-ensembles \mathcal{R}_i (appelées régions) de l'image, vérifiant :

$$\Pi \iff \begin{cases} \forall i, j \quad \mathcal{R}_i \cap \mathcal{R}_j = \emptyset \\ \bigcup_i \mathcal{R}_i = \text{support(image)} \\ \forall i \quad \mathcal{R}_i \neq \emptyset \end{cases}$$

- Notions de prédicat \mathcal{P}

prédicat de base : la région \mathcal{R}_i est homogène.

- contraste : $\mathcal{P}(\mathcal{R}_i) = \text{vrai} \iff \max_{\mathcal{R}_i} [f(x, y)] - \min_{\mathcal{R}_i} [f(x, y)] < \sigma$
- écart-type : $\mathcal{P}(\mathcal{R}_i) = \text{vrai} \iff \sqrt{\frac{1}{N} \sum_{(x,y) \in \mathcal{R}_i} (f(x, y) - m_i)^2} < \sigma$
(avec $N = \text{Card}(\mathcal{R}_i)$ et $m_i = \frac{1}{N} \sum_{\mathcal{R}_i} f(x, y)$),
- distance interquartile
- différences limitées : $\mathcal{P}(\mathcal{R}_i) = \text{vrai} \iff \forall (k, j) \text{ voisins}, |f(k) - f(j)| < \sigma$

- **Problème** : trouver une partition vérifiant le prédictat avec un **critère** sur la partition :
 - le cardinal de la partition (à minimiser),
 - la taille de la plus petite région (à maximiser),
 - une *distance entre régions* (par exemple somme des distances entre zones adjacentes) (à maximiser).

Recherche uniquement des **partitions maximales**, i.e :

$$\forall (i, j : i \text{ et } j \text{ adjacents} \Rightarrow \mathcal{P}(\mathcal{R}_i \cup \mathcal{R}_j) = \text{faux}$$

pas de stratégie optimale générale pour calculer la partition

- **La croissance de régions**

Principe : sélection de germes puis association de pixels qui vérifient le prédicat

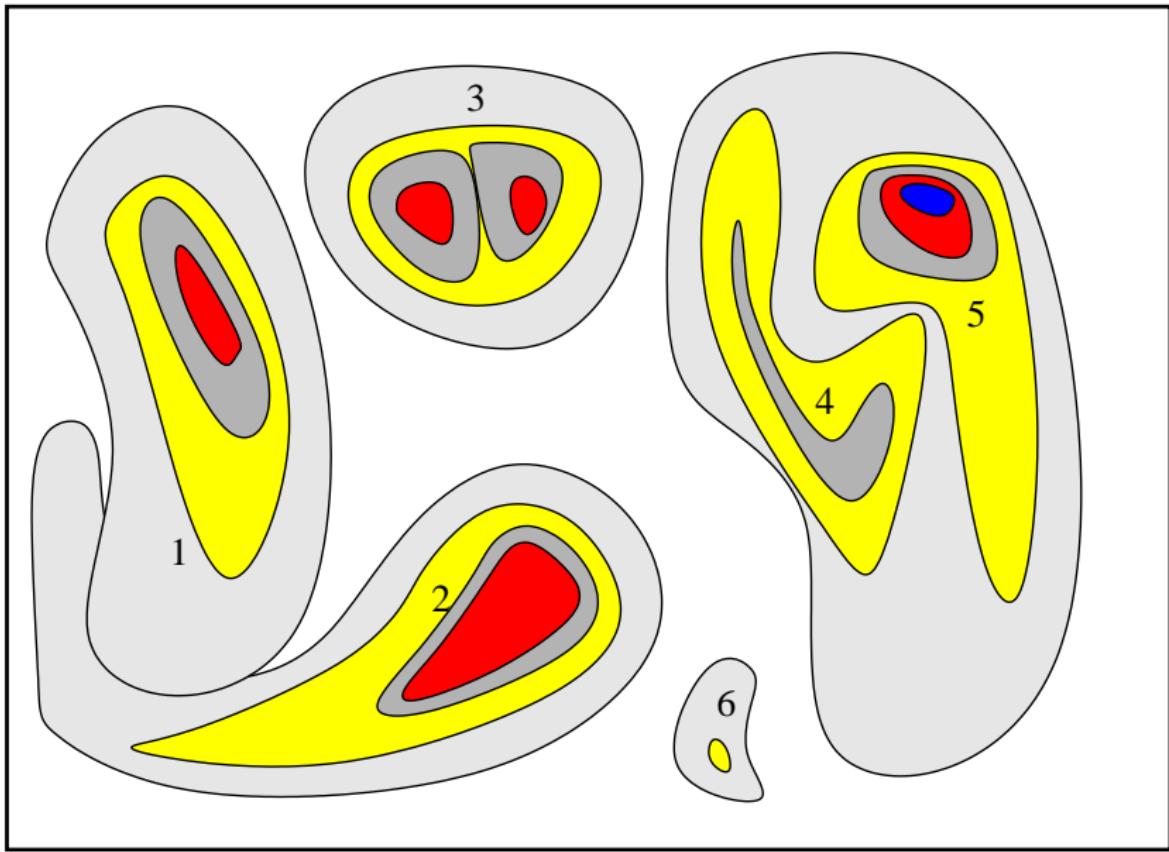
Réduction progressive de la sévérité du prédicat

Etape de fusion de régions adjacentes

Inconvénient : on n'obtient pas une partition totale

Sélection automatique des germes : critère sur l'homogénéité locale

Méthodes par transformation de régions



Méthodes par croissance de régions

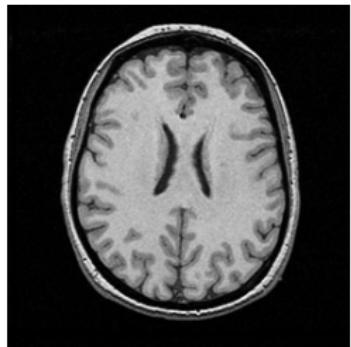


image originale



$t = 1$



$t = 2$



$t = 3$



$t = 4$

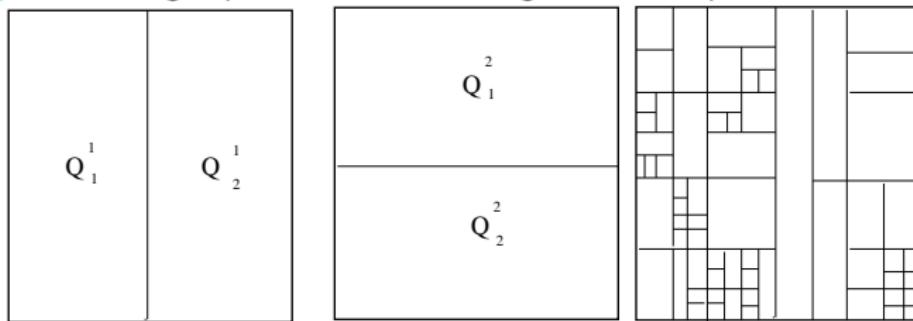


$t = 5$

- Le partage de régions

Principe : subdivision successive de l'image entière tant que le prédictat n'est pas vérifié.

Etape finale : regroupement éventuel de régions selon le prédictat



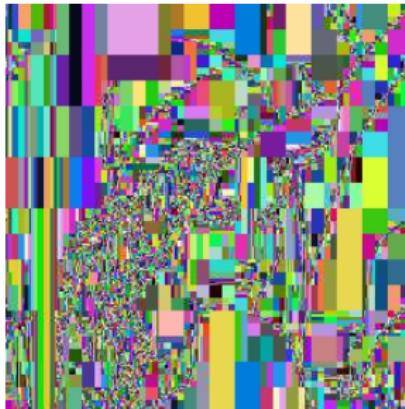
Inconvénient : stratégie trop rigide, dépend de l'ordre d'étude des régions

- Le partage de régions

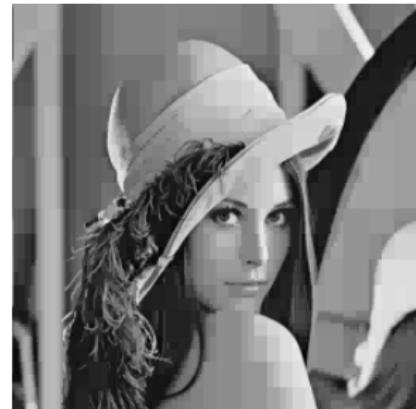
degré = 0, erreur = 10 : 9009 régions



image originale



segmentation



reconstruction

- Le partage de régions

degré = 1, erreur = 10 : 3108 régions

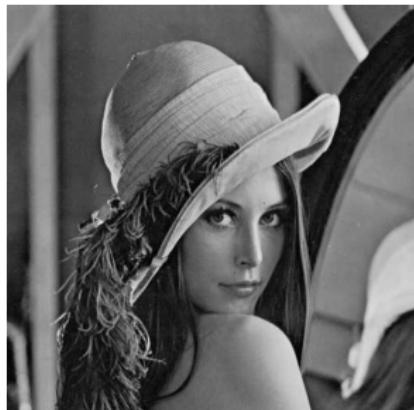
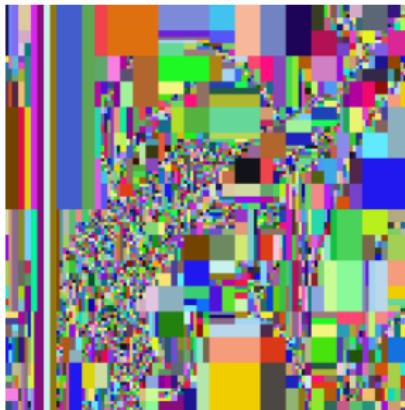


image originale



segmentation



reconstruction

- Le partage de régions

degré = 2, erreur = 10 : 1306 régions



image originale



segmentation



reconstruction

- Le partage de régions

degré = 3, erreur = 10 : 1040 régions



image originale



segmentation



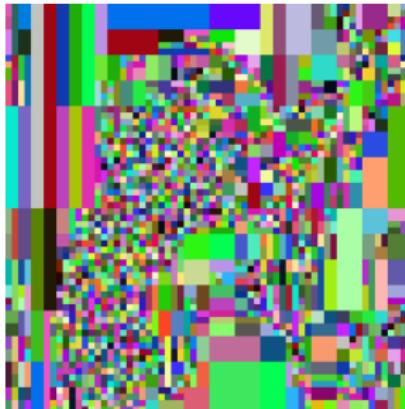
reconstruction

- Le partage de régions

degré = 3, erreur = 5 : 1678 régions



image originale



segmentation



reconstruction

- **Principe**

regroupement des régions à partir d'une partition fine (par ex. 2×2 pixels)

- **Approches statistiques**

Tests statistiques entre deux régions à fusionner : comparaison des distributions ou de certains moments

- test du Chi2 (χ^2),
- test de Student (égalité des espérances) :

$$T(n_1 + n_2 - 2) = \frac{(m_1 - m_2)\sqrt{n_1 + n_2 - 2}}{\sqrt{(n_1\sigma_1^2 + n_2\sigma_2^2)(1/n_1 + 1/n_2)}}$$

- test de Fisher-Snedecor (égalité des moyennes et des variances) :

$$F(n_1 - 1; n_2 - 1) = \frac{n_1\sigma_1^2(n_2 - 1)}{n_2\sigma_2^2(n_1 - 1)}$$

- Autres critères

- frontière peu contrastée
- amélioration d'un facteur de forme

- En pratique

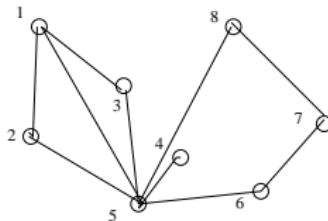
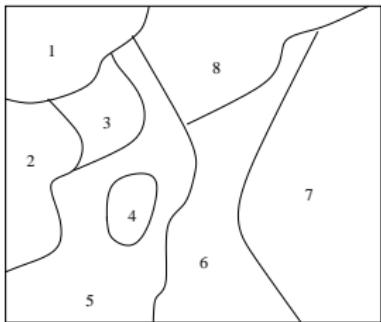
- calcul de tous les critères entre régions adjacentes
- fusion des régions les plus semblables au sens du critère
- mise à jour après fusion

- Inconvénient

résultats très dépendants de l'ordre de fusion des régions

• Graphe d'adjacence des régions

- calcul d'une sur-segmentation de l'image
(par ex. : ligne de partage des eaux - *watershed*)
- construction du graphe d'adjacence
- fusion des régions 2 à 2

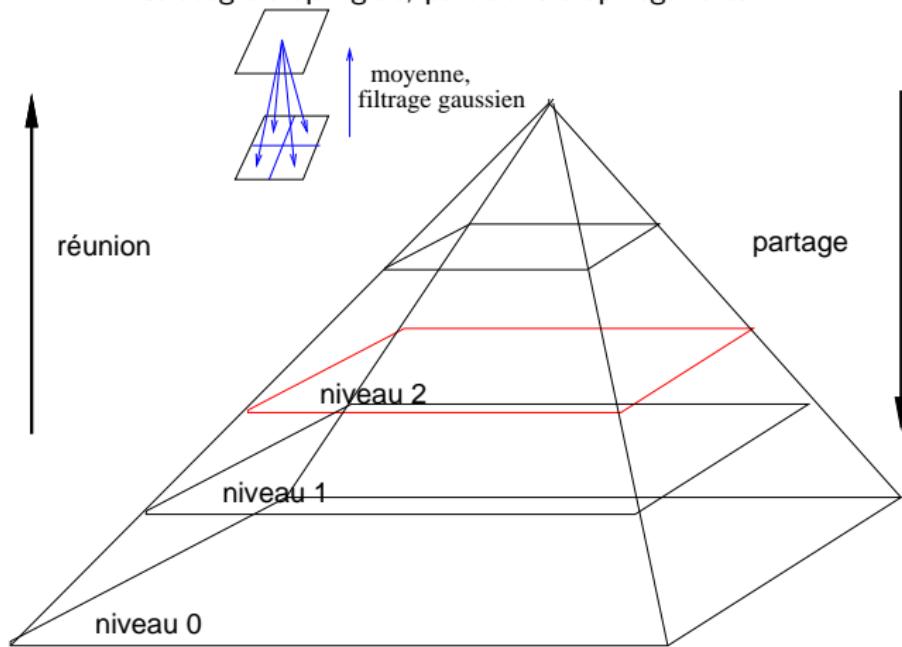


- **Les pyramides : partage et réunion**

Principe : création d'une pyramide d'images

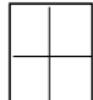
partant d'un niveau intermédiaire, passage au niveau supérieur si le prédictat est vérifié et inférieur sinon (lien entre chaque nœud et son père et ses fils)

Inconvénient : stratégie trop rigide, partitions trop régulières



Méthode de Suk & Chung

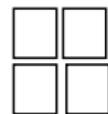
- Partage puis réunion de régions :



configuration d'étude



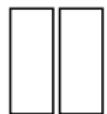
x 4



x 1



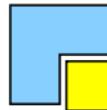
x 4



x 2

etape de partage

= 12



deja traité
non traité

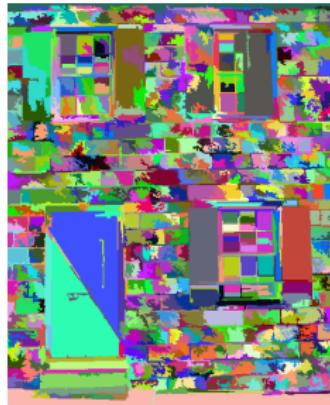
etape de reunion

+ étape d'élimination
des petites zones

Algorithme de Suk : exemples



image originale



suk : 5 5 100



suk : 10 10 100



suk : 20 20 100

Algorithme de Suk : exemples



image originale

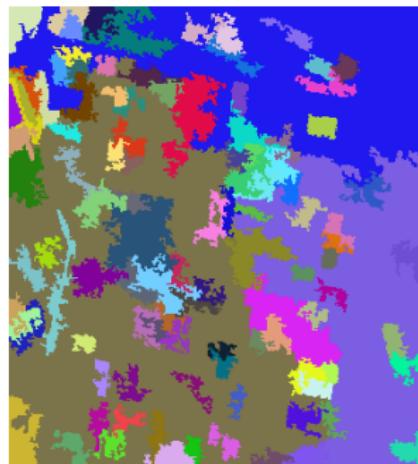


suk : 5 10 100



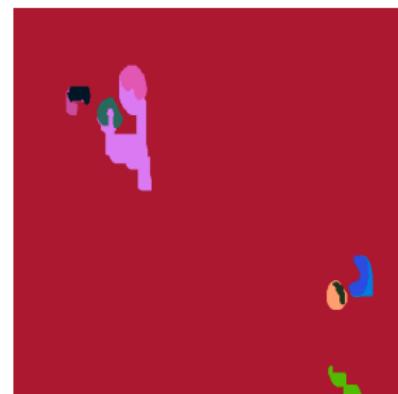
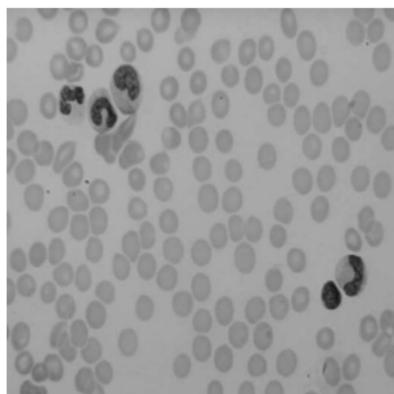
suk : 10 5 100

Algorithme de Suk : exemples



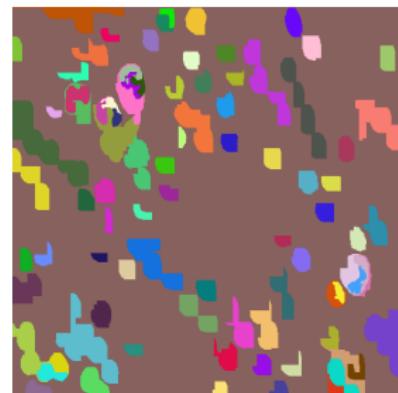
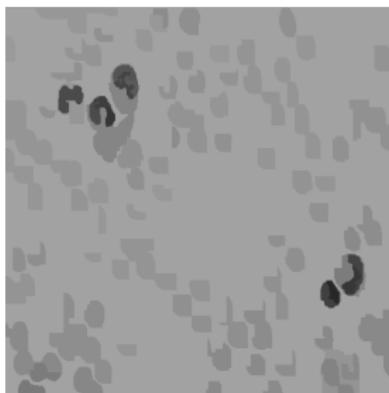
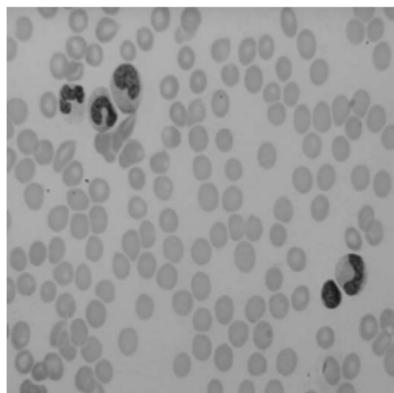
Algorithme de Suk : exemples

$T_1 = T_2 = 10, S = 200$: 11 régions



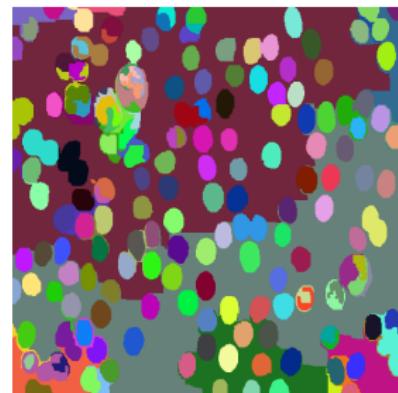
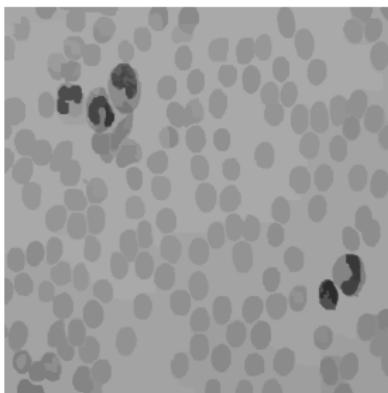
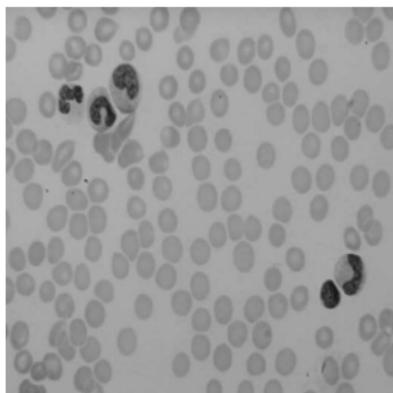
Algorithme de Suk : exemples

$T_1 = T_2 = 5, S = 200$: 90 régions



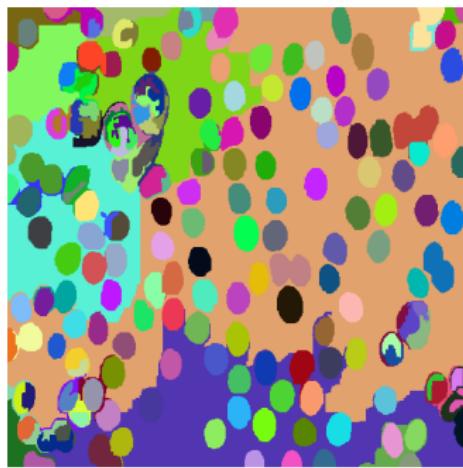
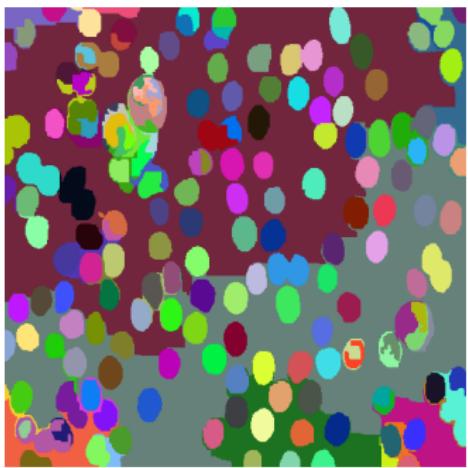
Algorithme de Suk : exemples

$T_1 = T_2 = 3, S = 200$: 193 régions



Algorithme de Suk : exemples

raw by raw / column by column



Application à la reconstruction 3D en stéréo

6 vues

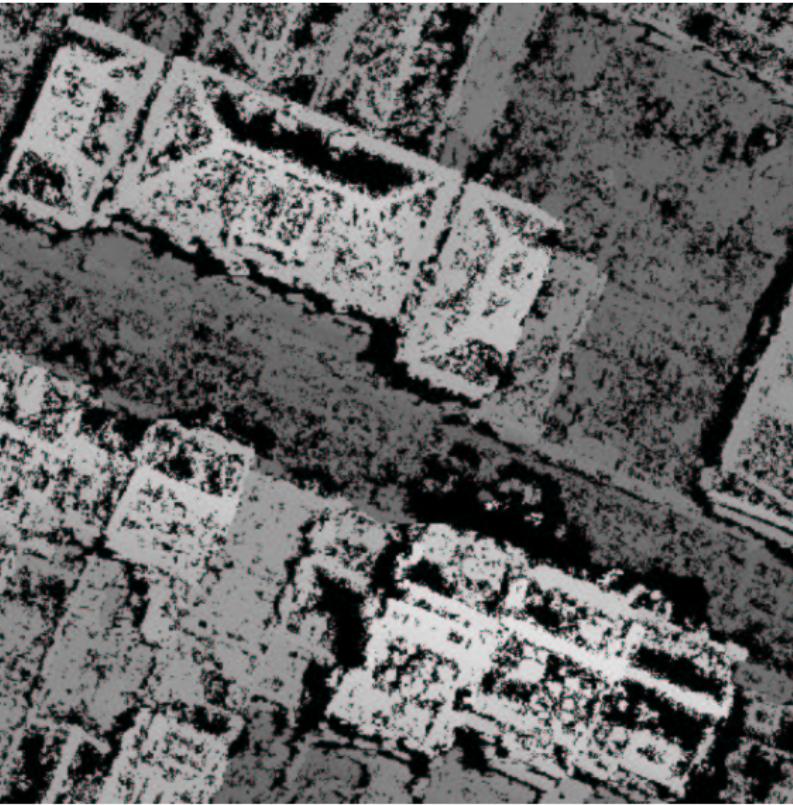


Application à la reconstruction 3D en stéréo

une vue

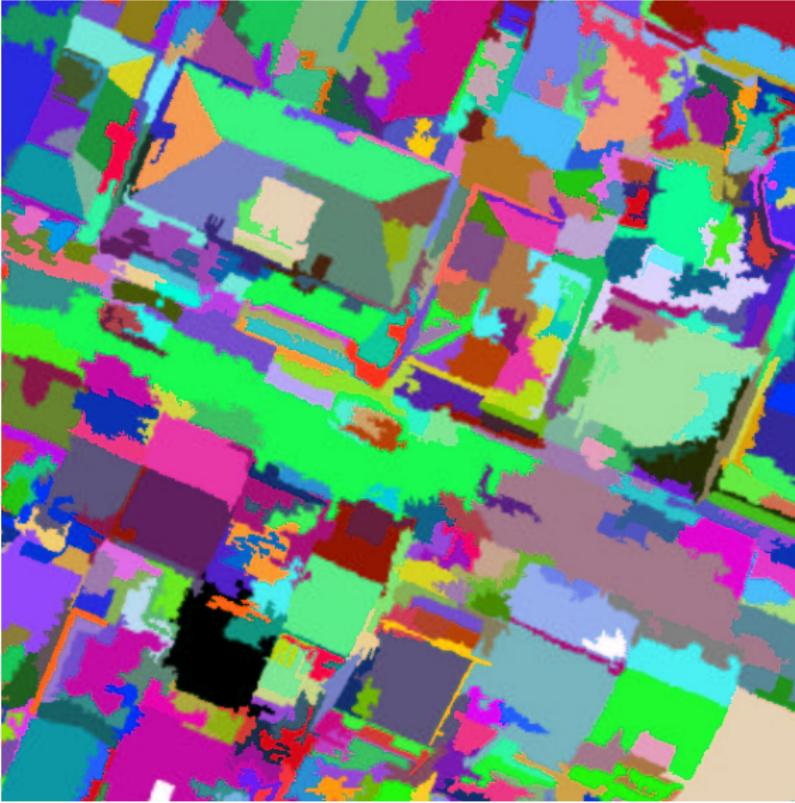


carte de disparité brute



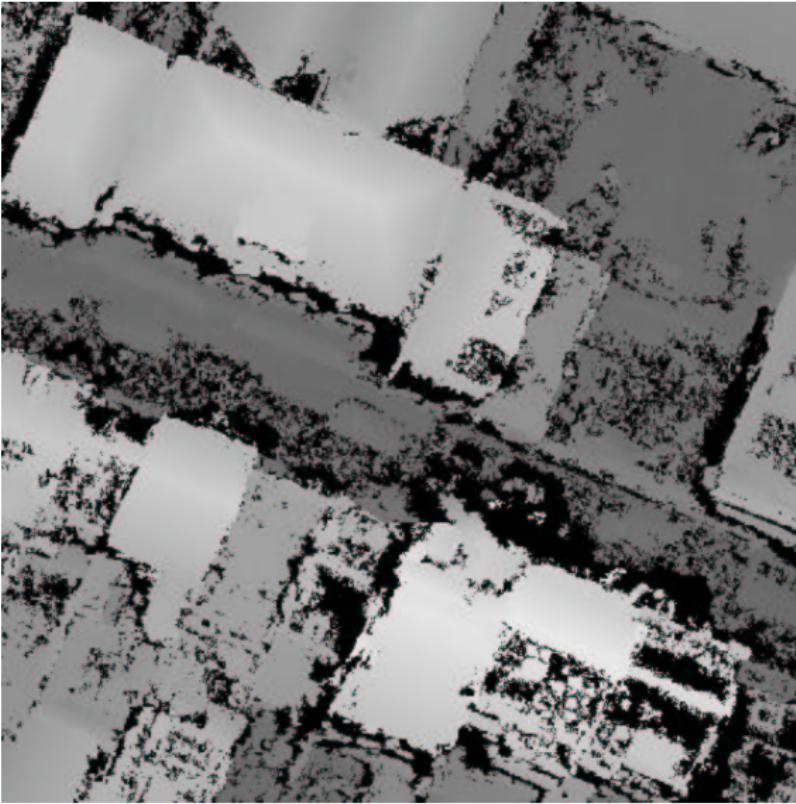
Application à la reconstruction 3D en stéréo

segmentation de l'image (Suk)

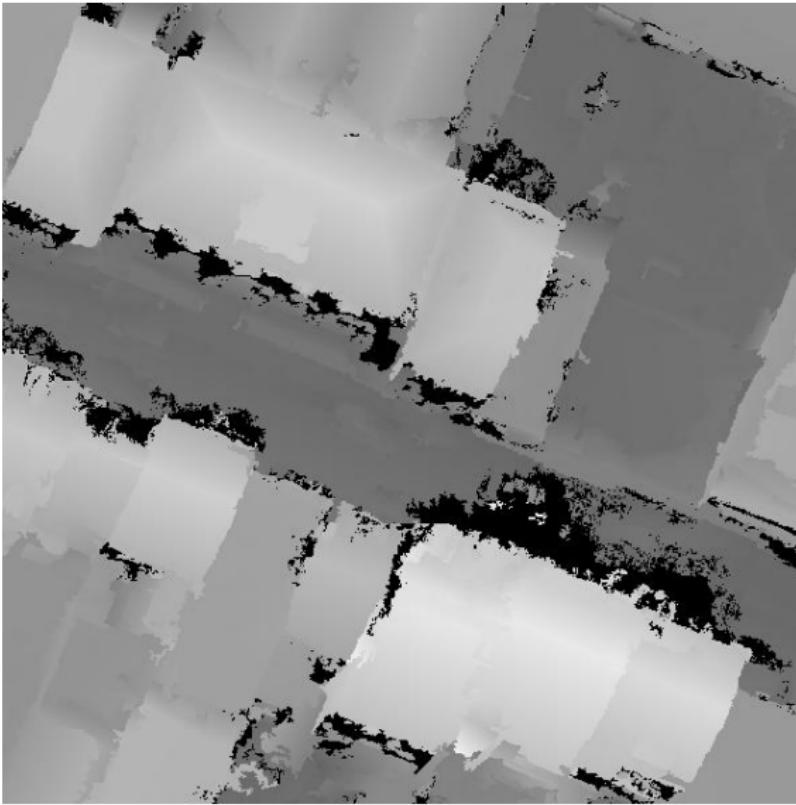


Application à la reconstruction 3D en stéréo

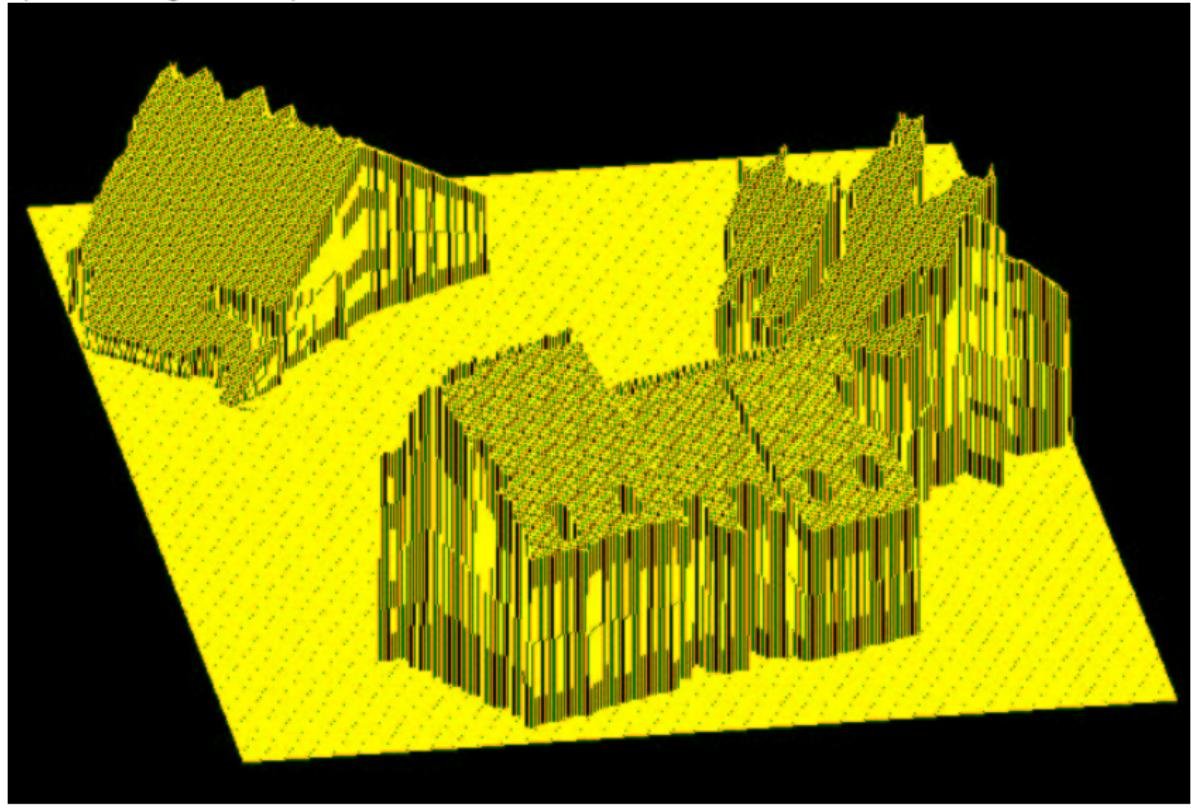
interpolation aux moindres carrés



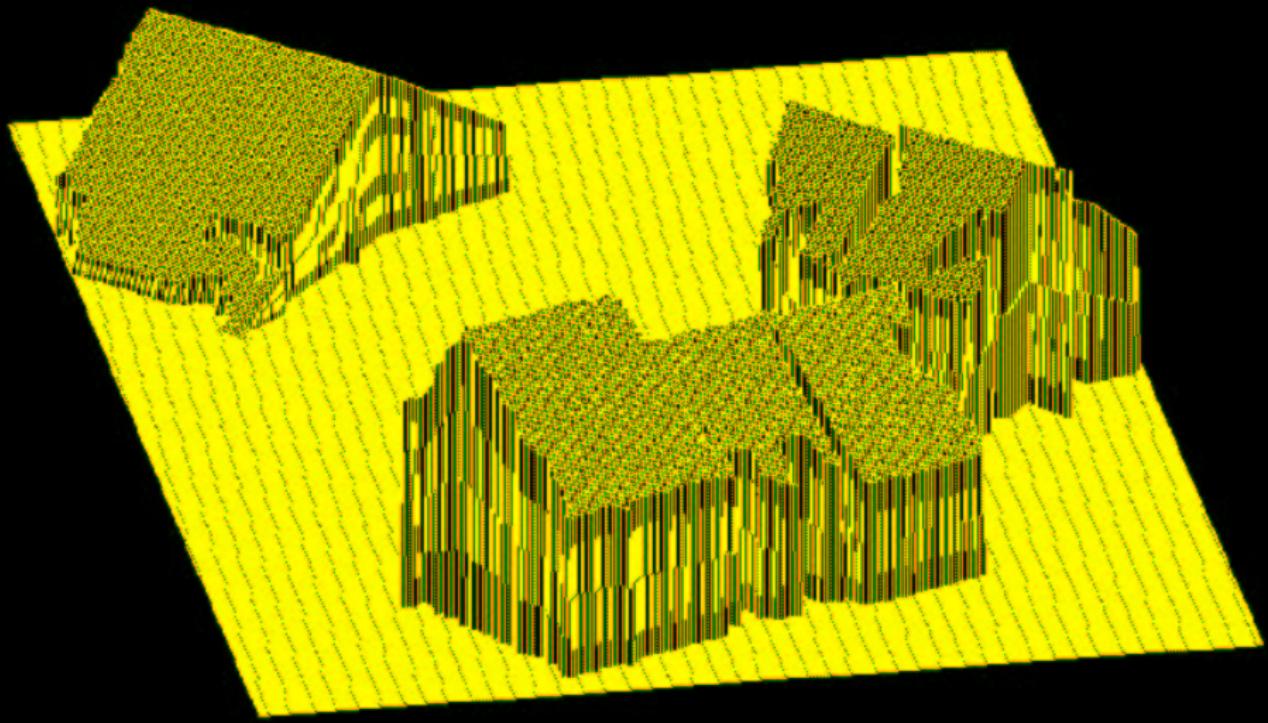
interpolation robuste



problèmes géométriques



Correction en utilisant des modèles 3D



Application à la reconstruction 3D en stéréo



Méthode SLIC + DBSCAN

SLIC : création de superpixels (petites régions)

- positionnement de k germes dans l'images (aléatoire, régulier...),
- chaque germe est caractérisé par sa position dans l'image et par sa couleur (RGB, Lab...),
- chaque pixel de l'image est affecté au germe le plus proche en fonction d'un critère : pondération d'une distance géométrique et d'une distance colorimétrique,
- mise à jour des germes (position et couleur), et retour à l'étape précédente.

DBSCAN : regroupement des superpixels

- regroupement des superpixels voisins sur un critère colorimétrique (RGB, Lab...)
- croissance de régions uniquement.

Génération de super-pixels (SLIC)

Nombre de régions : 1000



Génération de super-pixels (SLIC)

Nombre de régions : 500



Génération de super-pixels (SLIC)

Nombre de régions : 100



Génération de super-pixels (SLIC)

Nombre de régions : 2000



Génération de super-pixels (SLIC)

Nombre de régions : 1000



Clustering des super-pixels (DBSCAN)

Critère de distance : $d = 1$



Clustering des super-pixels (DBSCAN)

Critère de distance : $d = 2$



Clustering des super-pixels (DBSCAN)

Critère de distance : $d = 3$



Clustering des super-pixels (DBSCAN)

Critère de distance : $d = 4$



Clustering des super-pixels (DBSCAN)

Critère de distance : $d = 5$



Clustering des super-pixels (DBSCAN)

Critère de distance : $d = 6$



Clustering des super-pixels (DBSCAN)

Critère de distance : $d = 7$



Clustering des super-pixels (DBSCAN)

Critère de distance : $d = 8$



Clustering des super-pixels (DBSCAN)

Critère de distance : $d = 9$



Clustering des super-pixels (DBSCAN)

Critère de distance : $d = 10$



Clustering des super-pixels (DBSCAN)

Critère de distance : $d = 12$



Clustering des super-pixels (DBSCAN)

Critère de distance : $d = 15$



(Comaniciu & Meer, 2002)

- Filtrage

- modes principaux d'une fonction de densité,
- déplacement suivant le gradient de la densité,
- convergence vers les points stationnaires.

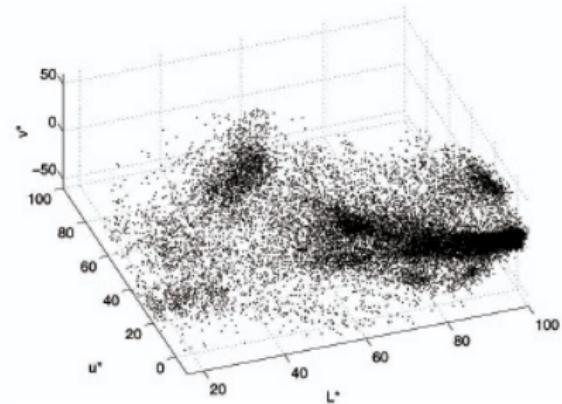
- Segmentation

- regroupement des points stationnaires proches,
- concaténation des bassins d'attraction.

exemple d'une fonction de densité



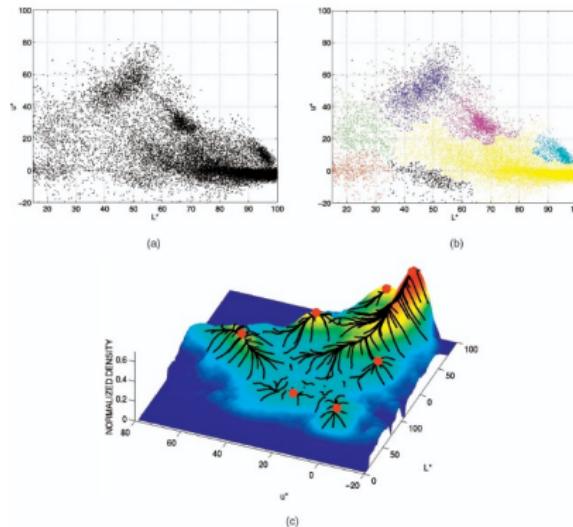
(a)



(b)

Fig. 1. Example of a feature space. (a) A 400×276 color image. (b) Corresponding $L^*u^*v^*$ color space with 110,400 data points.

déplacement suivant le gradient de la fonction de densité et convergence vers les points stationnaires



exemple de filtrage

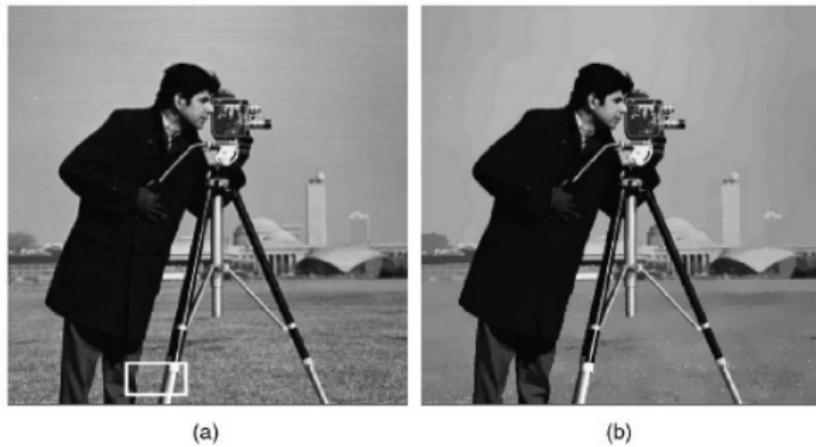
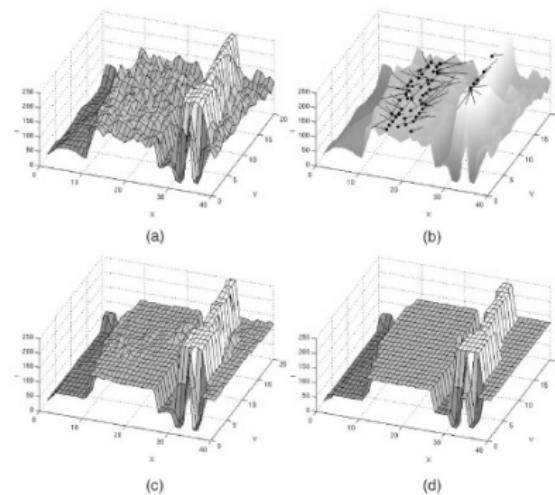


Fig. 3. Cameraman image. (a) Original. (b) Mean shift filtered $(h_s, h_r) = (8, 4)$.

regroupement des points stationnaires proches



segmentation d'une image à niveaux de gris

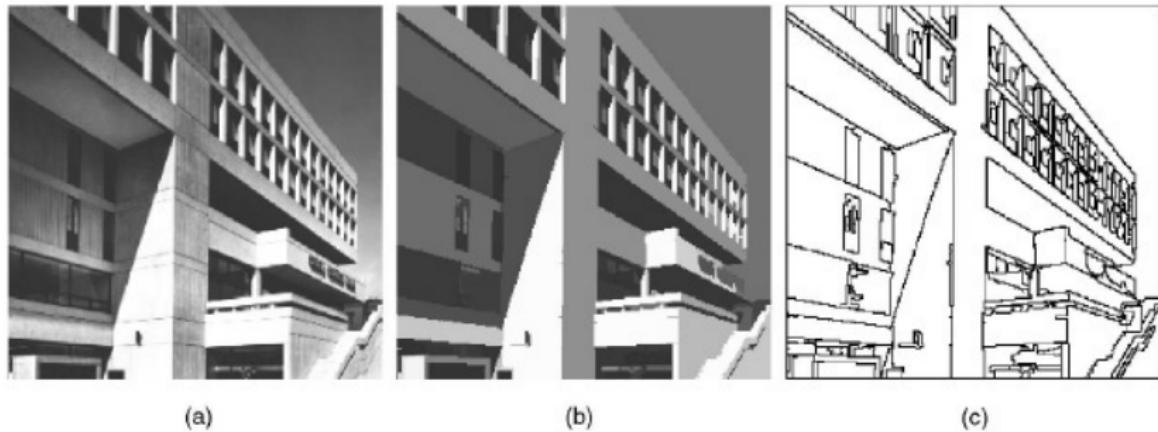


Fig. 6. MIT image. (a) Original. (b) Segmented $(h_s, h_r, M) = (8, 7, 20)$. (c) Region boundaries.



image originale



image filtrée



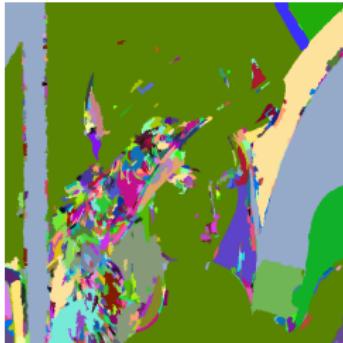
segmentation

Mean-shift

variation de la bande spatiale h_s



image originale



$h_s = 4$



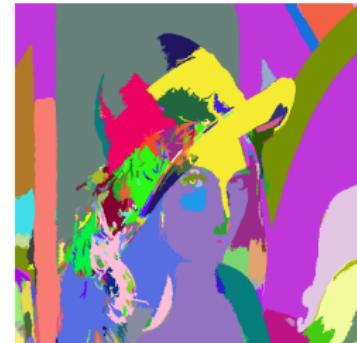
$h_s = 7$



$h_s = 10$



$h_s = 14$



$h_s = 20$

Mean-shift

variation de la bande radiométrique h_r



image originale



$h_r = 3$



$h_r = 6$



$h_r = 10$



$h_r = 15$



$h_r = 25$

images en couleur : choix de l'espace couleur



image originale



image filtrée



segmentation

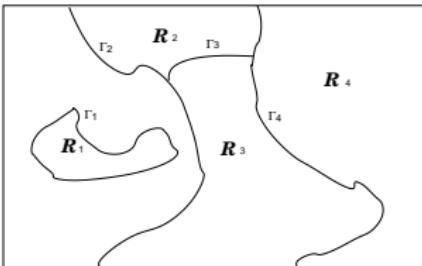
- 4 approches :

- fonctionnelle (Mumford et Shah 87)
- MDL (Minimum Description Length) (Leclerc 89)
- mécanique / résistance des matériaux (Blake et Zisserman 87)
- modèles markoviens (Geman et Geman 84)

4 approches différentes ⇒ critères très proches

f image

approximation de f par une fonction g régulière sur des régions \mathcal{R}_i limitées par des contours Γ_j



- Minimisation de la fonctionnelle

$$U(\Gamma, g, f) = \mu^2 \iint_{\mathcal{I}} (f(x, y) - g(x, y))^2 dx dy + \sum_i \iint_{\mathcal{R}_i} \|\nabla g(x, y)\|^2 dx dy + \sum_j \nu \int_{\Gamma_j} dl$$

- le premier terme mesure la qualité de l'approximation de f par g ,
- le deuxième terme assure la régularité de g à l'intérieur de chaque régions \mathcal{R}_i ,
- le troisième terme limite la longueur des contours entre les régions.

Que se passe-t-il si un des trois termes n'est pas pris en compte ?

film : MS